

Information Retrieval: Evaluierung und Beurteilung von IR-Systemen

Ingo Schmitt

Brandenburgische Universität Cottbus

Institut für Informatik

Lehrstuhl für Datenbank- und Informationssysteme



Welches System ist besser?

Web Bilder Maps News Shopping E-Mail Mehr ▼ Anmelden

Google

Information Retrieval Evaluierung Suche [Erweiterte Suche](#) [Einstellungen](#)

Suche: ☒ Das Web ☐ Seiten auf Deutsch ☐ Seiten aus Deutschland

Web Ergebnisse 1 - 10 von ungefähr 15.100 für **Information Retrieval Evaluierung**. (0,31 Sekunden)

[PDF] Evaluierung von Information Retrieval Systemen Die IR-Studie ...

Dateiformat: PDF/Adobe Acrobat - [HTML-Version](#)
 5. Juli 2007 ... Cranfield-Paradigma der **Evaluierung** im **Information Retrieval**. • Objektive Relevanz wird von neutralem Beobachter beurteilt ...
www.namics.com/fileadmin/user_upload/pdf/ir-studie2007D_1_cwh_Einfuehrung.pdf - [Ähnliche Seiten](#)

Experimentieller Evaluierung im Information Retrieval - Seminar ...

Experimentieller **Evaluierung** im **Information Retrieval** - Seminar, ... Verbunden mit Forschung im Bereich des **Information Retrieval** ist immer eine **Evaluierung**. ...
www.is.informatik.uni-duisburg.de/courses/exp_ws05/index.html - 13k - [Im Cache](#) - [Ähnliche Seiten](#)

Hauptseminar/Projekt: Implementierung und Evaluierung von ...

Hauptseminar/Projekt: Implementierung und **Evaluierung** von **Information-Retrieval**-Systemen. Seit drei Jahren gibt es parallel zur amerikanischen TREC-Studie ...
www.uni-hildesheim.de/de/6157.htm - 18k - [Im Cache](#) - [Ähnliche Seiten](#)

Systematisierung und Evaluierung von Clustering-Verfahren im ...

Systematisierung und **Evaluierung** von Clustering-Verfahren im **Information Retrieval**. Autor, Jens Kürsten. Betreuer, Prof. Dr. Maximilian Eibl ...
archiv.tu-chemnitz.de/pub/2006/0203/index.html - 12k - [Im Cache](#) - [Ähnliche Seiten](#)

[PDF] Evaluierung von Named Entity Recognition-Software für das cross ...

Dateiformat: PDF/Adobe Acrobat - [HTML-Version](#)
 Cross-linguales **Information Retrieval**. Eigennamen. Named Entity Recognition. **Evaluierung** der Named Entity Recognition-Software. Evaluierungsergebnisse ...
www.isi2004.ch/fileadmin/ISI/PDF-Dateien/StudBeitraege/Schnetzler.pdf - [Ähnliche Seiten](#)

Automatische Bewertung der Qualität von Web-Seiten - Information ...

Für die **Evaluierung** des Qualitäts-**Retrieval** wurden die Methoden der **Evaluierung** im **Information Retrieval** aufgegriffen und an einigen Stellen ...
expert.europspider.com/index.php?archives/28-Automatische-Bewertung-der-Qualitaet-von-Web-Seiten.html - 36k - [Im Cache](#) - [Ähnliche Seiten](#)

[PDF] Evaluierung von Information Retrieval Systemen ...

Dateiformat: PDF/Adobe Acrobat - [HTML-Version](#)
 Karin Haenelt, IR-**Evaluierung**. Status der Relevanzmenge. • "In all cases, evaluation of **Information Retrieval** Systems will suffer ..."
kontext.fraunhofer.de/haenelt/kurs/foien/IR-Evaluierung02-2.pdf - [Ähnliche Seiten](#)
 von K Haenelt - [Ähnliche Artikel](#) - [Alle 4 Versionen](#)

8.5 Evaluierung linktopologischer Verfahren aus: Dr. Dirk ...

Web **Information Retrieval**: Technologien für die Suche im Internet ... Bei der **Evaluierung** von linktopologischen Verfahren stellen sich zwei Fragen: ...
www.durchdenken.de/lewandowski/web-ir/785_Evaluierung_linktopologischer_Verfahren.html - 8k - [Im Cache](#) - [Ähnliche Seiten](#)

Evaluierung [R. Ferber: Information Retrieval]

Evaluierung [aus: R. Ferber: Suchmodelle und Data-Mining-Verfahren für Textsammlungen und das Web (<http://information-retrieval.de>)]
information-retrieval.de/irb/ir.part_2.chapter_3.section_9.topic_3.html - 9k - [Im Cache](#) - [Ähnliche Seiten](#)

[PS] Information Retrieval Skriptum zur Vorlesung im SS 93 Kapitel 3 ...

Dateiformat: Adobe PostScript - [HTML-Version](#)
Evaluierung. Wie in kaum einem anderen Teilgebiet der Informatik spielt die **Evaluierung** von Verfahren im **Information Retrieval** eine wichtige Rolle. ...
www.math.fu-berlin.de/teach/lect/ir/kap3.ps.gz - [Ähnliche Seiten](#)
 von N Fuhr - [Ähnliche Artikel](#) - [Alle 5 Versionen](#)

Anzeigen

[Informationsmanagement](#)
 Google Mini durchsucht über 220 Dateiformate. In 1h eingerichtet!
www.google.de/mini

Web Bilder Video Lokale Suche Shopping mehr ▼

Information Retrieval Evaluierung Suche Optionen ▼ Anpassen ▼

YAHOO! DEUTSCHLAND

Suche: ☒ Das Web ☐ Seiten auf Deutsch

1 - 10 von 50.200 für **Information Retrieval Evaluierung** - 0,39 Sek. | [Familienfilter ist Aus](#) | [SuchScan](#) ^{BETA} An

▲ 2 potenziell gefährliche Webseiten sind auf dieser Seite markiert.

SPONSOREN-LINKS

[So werden Sie Sponsor...](#)

Information Retrieval bei eBay

www.ebay.de - Neu und gebraucht. Sicher bei eBay kaufen und verkaufen.

Christa Womser-Hacker: Evaluierung im Information Retrieval

Herbstschule **Information Retrieval** - **Evaluierung** im **Information Retrieval** ... Tague, J.M. (1981), The Pragmatics of **Information Retrieval** Experimentation. ...
www.inf-wiss.uni-konstanz.de/IR/CD/DEMO/it/itcwh.htm - [Im Cache](#)

Sommerschule Information Retrieval 2001 der Fachgruppe Information

...
 Sommerschule **Information Retrieval** 2001. Weiterbildung der GI in Schloss Dagstuhl vom 26. ... **Evaluierung** von **Information-Retrieval**-Systemen (C. Womser-Hacker) ...
www.inf-wiss.uni-konstanz.de/IR/tutorate.html - [Im Cache](#)

[PDF] Information Retrieval

2184k - Adobe PDF - [Als HTML anzeigen](#)
Information Retrieval. Grundlagen, Modelle, Implementierung und ... 2. **Evaluierung**. c 1999 Andreas Henrich. **Information Retrieval** (Prof. Dr. Andreas Henrich) ...
www.dvs.informatik.uni-kl.de/courses/.../Information_Retrieval.full.pdf

Evaluierung [R. Ferber: Information Retrieval]

Evaluierung [aus: R. Ferber: Suchmodelle und Data-Mining-Verfahren für Textsammlungen und das Web (<http://information-retrieval.de>)]
information-retrieval.de/irb/ir.part_2.chapter_3.section_9.topic_3... - [Im Cache](#)

[PDF] 2. Evaluierung von Retrievalsystemen

277k - Adobe PDF - [Als HTML anzeigen](#)
Information Retrieval — FH Bonn-Rhein-Sieg, SS 06. 42. 2. **Evaluierung** von **Retrievalsystemen** ... 2. **Evaluierung** von **Retrievalsystemen**. Relevanz. Einflussfaktoren ...
www2.inf.fh-rhein-sieg.de/~pbecke2m/retrieval/eval1-4.pdf

[PDF] Information Retrieval Skriptum zur Vorlesung im SS 04

▲ **Warnung: Gefährliche Downloads**
 1750k - Adobe PDF - [Als HTML anzeigen](#)
 undigen Vorlesung "**Information Retrieval**" ... des **Information Retrieval**. Das ... Teilgebiet der Informatik spielt die **Evaluierung** von Verfahren im **Information** ...
www.is.informatik.uni-duisburg.de/courses/ir_ss04/foien/irskall.pdf

Experimentieller Evaluierung im Information Retrieval - Seminar, Winter

...
 ▲ **Warnung: Gefährliche Downloads**
 University of Duisburg, **Information Systems**. ... Experimentieller **Evaluierung** im **Information Retrieval** - Seminar, Winter 2005/2006 ...
www.is.informatik.uni-duisburg.de/courses/exp_ws05/index.html.en - [Im Cache](#)

Experimentieller Evaluierung im Information Retrieval - Seminar, Winter ...

University of Duisburg, **Information Systems**. ... Experimentieller **Evaluierung** im **Information Retrieval** - Seminar, Wintersemester 2005/2006 ...
www.is.inf.uni-due.de/courses/exp_ws05/index.html - [Im Cache](#)

Karin Haenelt: Kurs "Information Retrieval" - Kursbeschreibung

Evaluierung. Sprachverarbeitung im **Information Retrieval** (14) ... **Evaluierung** von dokumentenorientierten **Informationssystemen** wie **Information Retrieval**, Fakten ...
kontext.fraunhofer.de/haenelt/kurs/foien/ir/kap3.ps.gz - [Ähnliche Seiten](#)

Welche Variante bringt das bessere Ergebnis?

Web Bilder Maps News Shopping E-Mail Mehr ▼ Anmelden

Google Suche [Erweiterte Suche](#) [Einstellungen](#)

Suche: ☒ Das Web ☐ Seiten auf Deutsch ☐ Seiten aus Deutschland

Web Ergebnisse 1 - 10 von ungefähr 4.520.000 für BMW R 1100 R. (0,11 Sekunden)

BMW R 1100 R Test und Preisvergleich
Alle 200 ähnlichen Angebote für BMW R 1100 R anzeigen BMW hat die alte R 1100 R zumindest optisch deutlich modernisiert, der teilelevel wurde komplett ...
[www.ciao.de/BMW_R_1100_R_135975](#) - 134k - [Im Cache](#) - [Ähnliche Seiten](#)

BMW R 1100 R
BMW R 1100 R - ein Test- und Erfahrungsbericht vom Biker für Biker.
[www.bikeandmedia.de/r11r.htm](#) - 17k - [Im Cache](#) - [Ähnliche Seiten](#)

1000ps.de - Gebrauchte BMW R 1100 R - gebrauchte
Kostenlos Motorräder kaufen und verkaufen auf 1000PS. Keine Einstellgebühr, keine Provision. 11.000 Gebrauchte Motorräder von 600 Händlern und ...
[www.1000ps.de/gebrauchte-motorraeder-7-40-BMW_R_1100_R](#) - 78k - [Im Cache](#) - [Ähnliche Seiten](#)

wer-weiss-was | "BMW R 1100 R" | aus Forum Motorräder
2 Einträge
ich spiele mit dem Gedanken mir eine BMW R 1100 R zu zulegen. Hat jemand Erfahrung mit dem Bike und kann mir ein paar nützliche Tipps geben?
[www.wer-weiss-was.de/theme108/article371881.html](#) - [Ähnliche Seiten](#)

MOTORRAD online - Gebrauchterberatung BMW R 1100/1150/1200 GS
Gebraucht-Vergleichstest BMW R 1100/1150/1200 GS. Trio mit vier Ventilen. Böse Zungen behaupten, mit BMW-Motorrädern verhalte es sich wie mit Bananen – sie ...
[www.motorradonline.de/test/gebrauchterberatung-gebrauchterberatung-bmw-r-1100-1150-1200-gs.255143.htm](#) - 64k - [Im Cache](#) - [Ähnliche Seiten](#)

Testbericht zu BMW R 1100 R - Test und Meinungen bei dooyoo.de
Testbericht zu BMW R 1100 R mit Verbrauchermessung und Kaufempfehlung.
[www.dooyoo.de/motorrad/bmw-r-1100-r/Testberichte/](#) - 50k - [Im Cache](#) - [Ähnliche Seiten](#)

BMW R 1100 R - Testberichte und Preisvergleich von Shops
BMW R 1100 R - Motorrad mit Testberichten und Angeboten im Preisvergleich bei dooyoo.de - Kaufberatung und Tests für BMW - Motorrad.
[www.dooyoo.de/motorrad/bmw-r-1100-r/](#) - 62k - [Im Cache](#) - [Ähnliche Seiten](#)

Spezielles Zubehör für die R 1100 R
Zubehör für BMW R1100GS und R1100R und K1200RS der Fa. Scherb GmbH.
Motorradtechnik. ... R 1100 R BMW - BMW - BMW - BMW - BMW - BMW - BMW ...
[www.scherb-s.de/r1100r.htm](#) - 7k - [Im Cache](#) - [Ähnliche Seiten](#)

BMW R 1100 GS – Wikipedia
R 1100 GS ist die Modellbezeichnung eines Motorrads mit Boxermotor vom Typ Reiseenduro der Marke BMW. Dieses Modell wurde in der Zeit von 1994 bis 1999 über ...
[de.wikipedia.org/wiki/BMW_R_1100_GS](#) - 22k - [Im Cache](#) - [Ähnliche Seiten](#)

[www.bma-magazin.de/Rubriken/Archiv/Fahrberichte/BM...](#)
[Ähnliche Seiten](#)

Goooooooooooooogle  [Vorwärts](#)

Suche

In den Ergebnissen suchen | Sprachtools | Suchtrends

Web Bilder Maps News Shopping E-Mail Mehr ▼ Anmelden

Google Suche [Erweiterte Suche](#) [Einstellungen](#)

Suche: ☒ Das Web ☐ Seiten auf Deutsch ☐ Seiten aus Deutschland

Web Ergebnisse 1 - 10 von ungefähr 59.000 für "BMW R 1100 R". (0,40 Sekunden)

BMW R 1100 R Test und Preisvergleich
Angebote zu BMW R 1100 R - 73 Erfahrungsberichte - 73 Erfahrungsberichte - 73 Erfahrungsberichte - 3050 Erfahrungsberichte - 0 Erfahrungsberichte - 20 ...
[www.ciao.de/BMW_R_1100_R_135975](#) - 134k - [Im Cache](#) - [Ähnliche Seiten](#)

BMW R 1100 R - Lesen Sie Erfahrungsberichte
Lesen Sie 21 BMW R 1100 R Testberichte und machen Sie ein Schnäppchen.
[www.ciao.de/Erfahrungsberichte/BMW_R_1100_R_135975](#) - 90k - [Im Cache](#) - [Ähnliche Seiten](#)
[Weitere Ergebnisse von www.ciao.de >](#)

BMW R 1100 R
BMW R 1100 R - ein Test- und Erfahrungsbericht vom Biker für Biker.
[www.bikeandmedia.de/r11r.htm](#) - 17k - [Im Cache](#) - [Ähnliche Seiten](#)

1000ps.de - Gebrauchte BMW R 1100 R - gebrauchte
Kostenlos Motorräder kaufen und verkaufen auf 1000PS. Keine Einstellgebühr, keine Provision. 11.000 Gebrauchte Motorräder von 600 Händlern und ...
[www.1000ps.de/gebrauchte-motorraeder-7-40-BMW_R_1100_R](#) - 78k - [Im Cache](#) - [Ähnliche Seiten](#)

wer-weiss-was | "BMW R 1100 R" | aus Forum Motorräder
2 Einträge
ich spiele mit dem Gedanken mir eine BMW R 1100 R zu zulegen. Hat jemand Erfahrung mit dem Bike und kann mir ein paar nützliche Tipps geben?
[www.wer-weiss-was.de/theme108/article371881.html](#) - [Ähnliche Seiten](#)

Testbericht zu BMW R 1100 R - Test und Meinungen bei dooyoo.de
Testbericht zu BMW R 1100 R mit Verbrauchermessung und Kaufempfehlung.
[www.dooyoo.de/motorrad/bmw-r-1100-r/Testberichte/](#) - 50k - [Im Cache](#) - [Ähnliche Seiten](#)

BMW R 1100 R - Testberichte und Preisvergleich von Shops
BMW R 1100 R - Motorrad mit Testberichten und Angeboten im Preisvergleich bei dooyoo.de - Kaufberatung und Tests für BMW - Motorrad.
[www.dooyoo.de/motorrad/bmw-r-1100-r/](#) - 62k - [Im Cache](#) - [Ähnliche Seiten](#)

[www.bma-magazin.de/Rubriken/Archiv/Fahrberichte/BM...](#)
[Ähnliche Seiten](#)

BMW R 1100 R | BMW Straße über 750 (Verkaufen)
dhd24.com - das große Kleinanzeigen-Portal: BMW R 1100 R gebraucht kaufen und verkaufen.
[www.dhd24.com/archiv/index.php?anzid=10171940](#) - 21k - [Im Cache](#) - [Ähnliche Seiten](#)

BMW R 1100 R (259). Bi 95-01 - TLO BikeShop - Motorradersatzteile ...
Bremsbeläge, Bremsscheiben, Leitungen, Filter, Batterien, Kettensätze, Federn, Dichtungen, Lager und viele andere Verschleiß- und Ersatzteile für die BMW R ...
[www.tlo-bikeshop.de/index.php/cPath/149_475_530/category/r-1100-r.html](#) - 41k - [Im Cache](#) - [Ähnliche Seiten](#)

Bmw in Nürnberg?
Deutschlands größter Fahrzeugmarkt für Neu- und Gebrauchtwagen.
[www.mobile.de/nuernberg](#) Nürnberg

Wunderlich
Complete your BMW
Zubehör für BMW Motorräder
[www.wunderlich.de](#)

R 1100 R
Top-Angebot: R 1100 R
R 1100 R hier kaufen!
[Kaufen eBay.de/R+1100+R](#)

BMW R 1100 R Zubehör
für Ihre individuelle BMW R 1100 R
Beste Qualität, top Preise!
[www.motorradzubehoer-hornig.de](#)

Bmw R 1100 R bei Amazon
Größte Auswahl an Büchern.
Jetzt portofrei bestellen!
[Amazon.de/buecher](#)

Bmw-r-1100-r
Jetzt kostenlos kaufen & verkaufen
Die Motorradbörse von Kijiji
[www.kijiji.de](#)

Bmw r 1100 r
Alles zu Bmw r 1100 r
Bmw r 1100 r - Jetzt bei Ask!
[www.ask.com](#)

Bmw R 1100 R
Bmw R 1100 R - alle Produkte
vergleichen & super günstig kaufen!
[www.Preisvergleich.de/Bmw](#)

Goooooooooooooogle  [Vorwärts](#)

Suche

Ziele der Evaluierung

- Ziele der Evaluierung von IR-Systemen:
 - **vergleichende** Betrachtung zwischen mehreren IR-Systemen
 - Konstruktion und **Konfiguration** eines IR-Systems

- Exkurs: Evaluierung bei Datenbanksystemen
 - **Funktionsumfang** (teils standardisiert: z.B. SQL)
 - Laufzeit**effizienz** und Speicherplatzeffizienz

Effizienz vs. Effektivität

- **Effizienz** → möglichst sparsamer Umgang mit Ressourcen
 - In der Informatik typisch: Laufzeit- und Speicherplatzeffizienz
 - „Wird das, was gemacht wird, richtig (effizient) ausgeführt?“
 - vergleichende Betrachtung verschiedener Systeme nur bei gleichwertigen bzw. identischen Ergebnissen sinnvoll.
- **Effektivität** → Effektivität setzt die Qualität eines Ergebnisses ins Verhältnis zum Aufwand
 - „Werden die richtigen Dinge ausgeführt?“
- **Effektivität** zielt damit immer auf eine technische Lösung, bei der **Aufwand und Nutzen** in einem günstigen Verhältnis zueinander stehen.

Relevanz

- Bei der Evaluierung von IR-Systemen geht man davon aus, dass bezogen auf eine Anfrage q die **Dokumentensammlung in zwei Teile zerfällt**:
 - R_q die Menge der zur Anfrage relevanten Dokumente
 - $\overline{R}_q$ die Menge der für die Anfrage nicht relevanten Dokumente
- Diese Annahme führt dazu, dass **ein IR-System genau R_q liefern sollte**.
- Man kann damit die Qualität des Ergebnisses durch die **Abweichung von R_q** beschreiben.

Probleme der zweiwertigen Definition der Relevanz

- Die Aufteilung hängt vom **Vorwissen des Anfragers** ab!
 - Die Relevanz bestimmter Dokumente kann ggf. nur mit Vorkenntnissen erkannt werden!
 - Andererseits sind ggf. einführende Überblicksartikel nur für den Laien interessant!
- Die **Relevanz von Dokumenten kann voneinander abhängen**.
 - So kann z.B. die Relevanz eines Dokumentes b erst durch das Lesen eines anderen Dokumentes a deutlich werden.
 - Folge: Ist a im Ergebnis, so ist b relevant, sonst nicht!
- Eine **zweiwertige Relevanzskala** erscheint zu **vereinfachend**.
 - Sicherlich wäre eine mehrstufige oder gar eine stetige Skala realistischer.
 - Das Problem wäre aber: es wird noch schwerer eine allgemein anerkannte Einordnung der Dokumente bezüglich einer Anfrage zu finden.

Recall und Precision

	relevant	nicht relevant	Σ
im Ergebnis	a (hits)	b (noise)	$a + b$
nicht im Ergebnis	c (misses)	d (rejected)	$c + d$
Σ	$a + c$	$b + d$	$a + b + c + d$


- Der Recall beantwortet die Frage: *Wie vollständig ist die Antwort?*

$$\text{Recall} = \frac{a}{a + c} = \frac{\text{Anzahl der relevanten Dokumente im Ergebnis}}{\text{Gesamtzahl der relevanten Dokumente}}$$

- Die Precision beantwortet die Frage: *Wie genau ist die Antwort?*

$$\text{Precision} = \frac{a}{a + b} = \frac{\text{Anzahl der relevanten Dokumente im Ergebnis}}{\text{Gesamtzahl der Dokumente im Ergebnis}}$$

Eine andere Darstellung



$$\text{Recall} = \frac{R_q \cap \text{Erg}}{R_q}$$

$$\text{Precision} = \frac{R_q \cap \text{Erg}}{\text{Erg}}$$


Das F-Measure

- **kombiniert** die beiden klassischen Maße Recall und Precision
- definiert gewichtetes **harmonisches Mittel** aus Recall und Precision
- Häufig findet die ungewichtete Variante mit $\alpha = 0.5$ Anwendung



$$F - \text{Measure} = \frac{Precision \cdot Recall}{(1 - \alpha) \cdot Recall + \alpha \cdot Precision}$$



F-Measure



Vergleich mehrerer Systeme



Bestimmung des Recall (1/2)

- Vollständige Relevanzbeurteilung einer repräsentativen Stichprobe
 - Problem: Anteil der relevanten Dokumente i. Allg. sehr gering
 - $\Rightarrow$ die Stichprobe muss sehr groß sein, was zu einem großen Aufwand führt.

$$\text{Recall} = \frac{a}{a + c} = \frac{\text{Anzahl der relevanten Dokumente im Ergebnis}}{\text{Gesamtzahl der relevanten Dokumente}}$$


Bestimmung des Recall (1/2)

- Dokument-Source-Methode
 - man wählt ein zufälliges Dokument aus der Datenbasis
 - man formuliert eine Frage, zu der dieses Dokument relevant ist
 - Man prüft, ob das Dokument tatsächlich in der Antwort ist.
 - Über mehrere Dokumente und Anfragen gemittelt ergibt sich ein Wert für den Recall
 - Problem: es handelt sich nicht um „echte“ Benutzerfragen


Bestimmung des Recall (2/2)

- Anfrageerweiterung
 - man erweitert die Anfrage, so dass eine Obermenge der ursprünglichen Antwortmenge gefunden wird
 - Z.B. mehrere **Frageformulierungen** von verschiedenen Bearbeitern
 - Problem: Man erhält trotzdem i. Allg. nur eine Teilmenge der relevanten Dokumente
 - Folge: **Recall-Schätzungen werden im allgemeinen zu hoch** sein!
- Abgleich mit externen Quellen
 - Man versucht parallel noch mit **unabhängigen Methoden**, relevante Dokumente zu bestimmen
 - so kann man den Fragenden oder andere **Fachleute** befragen, welche relevanten Dokumente sie kennen

Pooling Methode




Ellen Voorhees – CLEF 2001 Workshop



Vorgehen

- Intellektuelle Bewertung
 - relevant oder nicht relevant
- statistische Auswertung





- Quelle: TREC presentation slide No. 15

Text REtrieval Conference (TREC)

Distributed Information Retrieval Evaluation Campaign Tool (DIRECT) - Topic Selection - Mozilla Firefox

Datei Bearbeiten Ansicht Chronik Lesezeichen Extras Hilfe

http://direct.dei.unipd.it/protected/assessor/loadAssessorPool.do

Meistbesuchte Seiten Customize Links Free Hotmail Windows Media Windows

DIRECT

Distributed Information Retrieval Evaluation Campaign Tool

für das Cross Language Evaluation Forum (CLEF)

Angemeldet als mandl @ CLEF2008 [\[Abmelden\]](#)

Topic Selection

Abmeldung

Bewertungs-Hauptseite | User Management | Kontakte | Nachrichten

Bewertungs-Status	Name Datenbestand	Beschreibung Datenbestand	Bewertete Dokumente / Alle Dokumente
	10.2454/GC-ENGLISH-CLEF2008	GeoCLEF English Pool	14.528/14.528 100%
	10.2454/GC-GERMAN-CLEF2008	GeoCLEF German Pool	15.081/15.081 100%
	10.2454/GC-PORTUGUESE-CLEF2008	GeoCLEF Portuguese Pool	14.780/14.780 100%

★ Topic Kennung	📄 Topic Titel	🟡 Gesamt	🟢 Relevant	🔴 Nicht relevant	🟡 Nicht bewertet	Bewerten
10.2452/100-GC	Os documentos relevantes devem mencionar terremotos e enchentes nos estados da região oeste dos EUA	744	31	713	0	Assess Topic
10.2452/76-GC	Documentos que mencionem a existência de um motim em prisões da América do Sul	676	96	580	0	Assess Topic
10.2452/77-GC	Documentos que mencionem vencedores de Prêmios Nobel nascidos num país do Norte da Europa	630	31	599	0	Assess Topic
10.2452/78-GC	Documentos que mencionem eventos desportivos que ocorram em (ou passem por) localidades, países ou territórios cobertos total ou parcialmente pelo deserto	590	49	541	0	Assess Topic

Fertig

Distributed Information Retrieval Evaluation Campaign Tool (DIRECT) - Topic Assessment - Mozilla Firefox

Datei Bearbeiten Ansicht Chronik Lesezeichen Extras Hilfe

http://direct.dei.unipd.it/protected/assessor/assessment/assessTopic.do

Meistbesuchte Seiten Customize Links Free Hotmail Windows Media Windows

DIRECT Zurück

relevant << Document >> relevant Document >>
 nicht relevant << noch nicht geprüft Document >> nicht relevant Document >>

Topic	Dokumentkennung	Dokumenttitel	Relevanz
Information über Topic 10.2452/100-GC: Bewertete Dokumente / Alle Dokumente: 715/715 100% Topic Titel Naturkatastrophen im Westen der USA Topic Description Dokumente über Naturkatastrophen im Westen der USA Topic Narrative Relevante Dokumente sollten Informationen über Erdbeben, Überschwemmungen und Waldbrände in den westlichen Bundesstaaten der USA enthalten. Zu den westlichen Bundesstaaten zählen Kalifornien, Washington und Oregon.	FR940109-000121	Nordkorea und USA Vor Druck gewarnt	nicht relevant

Dokumentkörper

```
<DOCNO>FR940109-000121</DOCNO>
<WEEK> 940109 </WEEK>
<TITLE> Nordkorea und USA </TITLE> <TITLE> Nordkorea und USA Vor Druck gewarnt </TITLE> <TEXT>
WASHINGTON, 2. Januar (dpa ). Ungeachtet einer Annäherung zwischen den USA undNordkorea
inderstrittigenFrage der Atominspektionen hat der nordkoreanische Präsident Kim Il Sung Washington vor
Druck und Drohungen gewarnt. Solch ein Vorgehen könnte zur Katastrophe führen, sagte Kim laut
nordkoreanischer Nachrichtenagentur in einer Neujahrsadresse in Pjöngjang. Nach dem jüngsten Gespräch
zwischen Diplomaten beider Länder in New York hatte ein Sprecher des US-Außenministeriums trotz der offiziell
geltenden Nachrichtensperre bestätigt, man sei dem Ziel nähergekommen. Wie der US-Sender ABC unter
Berufung auf ungenannte Regierungsbeamte meldete, soll Nordkorea die Inspektion aller seiner insgesamt
sieben Atomanlagen durch internationale Experten erlaubt und damit eine Hauptforderung der USA erfüllt
haben. Nach nordkoreanischer Darstellung sollen die USA im Gegenzug bereit sein, auf die jährlichen
Militärmanöver mit Südkorea zu verzichten. </TEXT>
```

Documents

FR940109-000121 - nicht relevant View
Nordkorea und USA Vor Druck gewarnt

Document 2 / 715

FR940109-000467 - nicht relevant View
*940109 SYDNEY, 7. Januar rtr . Die schweren Buschfeuer in Australien haben am
Freitag die Vororte de*

Document 3 / 715

FR940109-001602 - nicht relevant View
940109 Präsident Bill Clinton hat ein Jahr gebraucht, bis er nach Europa kommt

Documents

Fertig

Mittelwertbildung über mehrere Anfragen

über m Experimente den Mittelwert bilden $\rightarrow$ 2 Möglichkeiten:

- 1. **Makrobewertung**; nutzungsorientierter Ansatz

$$Recall_{\phi,u} = \frac{1}{m} \cdot \sum_{i=1}^m \frac{a_i}{a_i + c_i} \quad Precision_{\phi,u} = \frac{1}{m} \cdot \sum_{i=1}^m \frac{a_i}{a_i + b_i}$$

- Hier gehen alle Experimente unabhängig von Ergebnisgröße gleich ein.
- Probleme gibt es, wenn einzelne Anfragen leere Ergebnisse liefern

$$a_i + b_i = 0$$

Mittelwertbildung über mehrere Anfragen

- 2. **Mikrobewertung** (systemorientiert)
 - Hier gehen Anfragen mit einer größeren Ergebnismenge stärker ein.
 - Summe aller Anfragen als „eine große Anfrage“ betrachtet.

$$Recall_{\phi,s} = \frac{\sum_{i=1}^m a_i}{\sum_{i=1}^m (a_i + c_i)} \quad Precision_{\phi,s} = \frac{\sum_{i=1}^m a_i}{\sum_{i=1}^m (a_i + b_i)}$$

Beispiel

Anfrage	$ Erg_q = a + b$	$ R_q = a + c$	$ R_q \cap Erg_q = a$	<i>Recall</i>	<i>Precision</i>
1	10	7	1	0,14	0,1
2	12	13	2	0,15	0,17
3	200	138	120	0,87	0,6
4	4	9	2	0,22	0,5
Summe	226	167	125		

■ Makrobewertung:

- Recall: $\frac{1}{4} * (0,14 + 0,15 + 0,87 + 0,22) = 0,35$
- Precision: $\frac{1}{4} * (0,1 + 0,17 + 0,6 + 0,5) = 0,34$


■ Mikrobewertung:

- Recall: $125/167 = 0,75$
- Precision: $125/226 = 0,55$
- “große” Anfrage 3 dominiert




Recall/Precision bei Systemen mit Ranking

Rang	Relevanz
1	1
2	0
3	1
4	0
5	0
6	1
7	0
8	1
9	0
10	0



Festlegung auf „Meßpunkte“
 meist Precision bei einem Recall von 0,1
 0,2 0,3 ...
 -> Mittelwert ->
 [Mean] Average Precision (MAP)



Wichtig: Benutzerstandpunkte und tatsächlich verwendete Maße

- MAP → Systemorientierter Ansatz
- Aber nicht direkt als Benutzerstandpunkt interpretierbar
- Ich sehe mir nur die Dokumente auf der **ersten Seite** an:
 - → P@10 oder P@5
- Ich schaue mir Dokumente **bis zum ersten irrelevanten** an:
 - Gute erste Treffer wichtig
- Discounted Cumulative Gain
 - Misst anhand von gradueller Relevanz des Nutzers den Gewinn (gain) an Relevanz durch ein Dokument an einer bestimmten Position



Discounted Cumulative Gain

- Grundlage: Graded Relevance vom Nutzer, z.B. [0;3] wobei 0 irrelevant bedeutet
- Annahme: Hochrelevante Dokumente sind am sinnvollsten bzgl. des Informationsgewinns, wenn sie eine vordere Position erreichen

$$DCG_p = rel_1 + \sum_{i=2}^p \frac{rel_i}{\log_2 i}$$



Normalized DCG

- DCG_p verschiedener Durchläufe nur nach Normalisierung vergleichbar -> nDCG_p
- Idee: Verhältnis zum idealen DCG -> IDCG_p
- IDCG_p: DCG_p nach absteigender Sortierung nach Nutzerrelevanz

$$\text{nDCG}_p = \frac{DCG_p}{IDCG_p}$$

- Durchschnitt von nDCG_p verschiedenen Experimente berechnen



Wichtig: Anfrage-Typen

- Navigational
 - Suche nach Homepage von Firma X
- Informational
 - Gelbe-Seiten-Anfragen
 - Faktenfragen (question answering)
 - Ad-hoc (Suche alles zum Thema X)
- Folge: Unterschiedliche Evaluierungserfordernisse, insbesondere beim Relevance Feedback

Cranfield Experiment [CMK66]: 6 Kriterien zur Evaluation von IR-Systemen

1. **Recall** → Fähigkeit des Systems alle relevanten Objekte zu finden
2. **Precision** → Fähigkeit des Systems nur die Objekte zu präsentieren, die relevant sind
3. **time lag** → die Zeit zwischen Absetzen der Anfrage und Bereitstellung der Antwort
4. **Effort** → der intellektuelle und physische Aufwand, der vom Benutzer zur Erlangung der Antwort erforderlich ist (z.B. komplexe Eingaben, Rückfragen des Systems, ...)
5. **form of presentation** → die Qualität der Ergebnisdarstellung, welche die Nützlichkeit für den Benutzer beeinflusst
6. **coverage of the collection** → der Grad, zu dem das System relevante Objekte enthält (mehr eine Frage der Dokumente als des Retrieval-Systems)


Vickery beschreibt 6 Kriterien, die er in zwei Gruppen unterteilt [Vic70]:

- Kriterien, die sich auf Verfügbarkeit von Informationen beziehen:
 - **coverage** — Anteil der möglicherweise nützlichen Literatur, der in Betracht gezogen wurde (z.B. bei mehreren verfügbaren Kollektionen: wurden alle mit potentiell relevanten Dokumenten betrachtet)
 - **recall** — Anteil der möglicherweise nützlichen Dokumente, die im Ergebnis der Anfrage enthalten sind
 - **response time** — durchschnittliche Antwortzeit
- Kriterien, die sich auf die Selektivität der Antwort beziehen:
 - **precision** — Fähigkeit des Systems unnütze Dokumente zu unterdrücken
 - **usability** — Wert der ermittelten Dokumente für den Benutzer (Zuverlässigkeit, Verständlichkeit, ...)
 - **presentation** — Form, in der die Ergebnisse präsentiert werden



Usability

- Besonderer Fokus im IR durch Nutzerfokus
- www.searchuserinterfaces.com/



Ziele Evaluierungsinitiativen

- Einheitliche **Bewertungsmaßstäbe** für Retrieval-Systeme (Stoßrichtung Standardisierung)
- **Vergleich** zwischen Systemen ermöglichen
- **Weiterentwicklung** von IR Systemen vorantreiben
- Anforderungen aus der Community aufnehmen und Methodik weiterentwickeln

TREC: *Text REtrieval* Conference

- „TREC is a new ballgame for IR research and development“ (Sparck Jones 1994)
- Evaluierungsinitiative des National Institute of Standards and Technology (NIST) in den USA
- 1992: TREC-1 (Proceedings 1993)



Text REtrieval Conference (TREC)

*...to encourage research in information retrieval
from large text collections.*



The TREC Conference series is co-sponsored by the NIST, [Information Technology Laboratory's \(ITL\) Retrieval Group](#) of the [Information Access Division \(IAD\)](#) and the [Intelligence Advanced Research Projects Activity \(IARPA\)](#).

Search the TREC site:

National Institute of Standards and Technology

is an agency of the [U.S. Commerce Department](#)

Last updated: Thursday, 28-Aug-2008 11:36:53 EDT

Date created: Tuesday, 01-Aug-00

[privacy policy](#) / [security notice](#) / [accessibility statement](#)

[disclaimer](#) / [FOIA](#)

trec@nist.gov

Vorgehen

■ Testbasis

- Objekte (Dokumente, ...) mit geklärtem Copyright
- Anfragen (Topics)
 - relevante Informationsbedürfnisse für pot. Benutzer
- einheitliche Relevanzbewertung

■ zeitlicher Rahmen (ca. 4 Monate gesamt)

- Ausgabe der Anfragen
- Einreichen von Ergebnissen
- Bekanntgabe der Ergebnisse


2008 TREC Tracks

- Blog Track
- Enterprise Track
- Legal Track
- Million Query Track
- Relevance Feedback Track

Past TREC Tracks

- Cross-Language Track
- Filtering Track
- Genomics Track
- HARD Track (High Accuracy Retrieval from Documents)
- Interactive Track
- Novelty Track
- Question Answering Track
- Robust Retrieval Track
- SPAM Track
- Terabyte Track
- Video Track
- Web Track

Question Answering



WolframAlpha™ computational... knowledge engine

scalar product

Assuming "scalar product" is a general topic | Use as **a word** instead

Vectors

compute properties of a vector

vector {2, -5, 4} =

compute the norm of a vector

norm {12, -5} =

Vector Algebra

do vector computations

$7 \{1, 0, -2, 1\} - 4 \{2, -1, 1, -1\}$ =

compute a dot product

$\{12, 20\} \cdot \{16, -5\}$ =

compute a cross product

$\{1/4, -1/2, 1\}$ cross $\{1/3, 1, -2/3\}$ =

New to Wolfram|Alpha?

A few things to try:

- enter any date (e.g. a birth date)
june 23, 1988
- enter any city (e.g. a home town)
new york
- enter any two stocks
IBM Apple
- enter any calculation
 $\$250 + 15\%$
- enter any math formula
 $x^2 \sin(x)$

[more »](#)

[Examples by Topic »](#)

[Visual Gallery of Examples »](#)

[Watch Overview Video »](#)

Search the Web

scalar product



Beispiel-Topic

<TOP>

<HEAD> Tipster Topic Description

<NUM> Number: 066

<DOM> Domain: Science and Technology

<TITLE> Natural Language Processing

<DESC>

Document will identify a ctype of natural language processing technology which is being developed or marketed in the U.S.

<NARR>

A relevant document will indentify a company or institution developing or marketing a natural language processing technology, identify the technology, and identify one or more features of the company's product.

<CON>NLP, translation, language, dictionary, font, software

<NAT> U.S.

</TOP>

TREC-3: ohne CON
TREC-4 und -5:
nur noch DESC
ab TREC-5:
Varianten *short* und
long

Beispiel-Dokument: Wall Street Journal

```
<DOC>
<DOCNO> WSJ880406-0090 </DOCNO>
<HL> AT&T Unveils Services to Upgrade Phone Networks Under
      Global Plan </HL>
<AUTHOR> Janet Guyon (WSJ Staff) </AUTHOR>
<DATELINE> New York </DATELINE>
<TEXT>
American Telephon & Telegraph Co. Introduced the first of a new
generation of phone services with broad ...
</TEXT>
</DOC>
```



Relevanz-Bewertung

- Abstraktion vom individuellen Benutzer und dessen Kontext
- Einheitliche Bewertung
- Objektive Juroren, die nicht in einer Benutzungssituation sind
- Objektive Aussage über inhaltlichen Zusammenhang zwischen Topic und Dokument

Cross-Language Evaluation Forum

Forschung zu cross- und
multi-lingualen
Information Retrieval
Systemen



EU Förderung: DELOS NoE
for Digital Libraries

Testumgebung


Systementwicklung

Benchmarks

Evaluationsforschung

Mandl et al. @ CLEF 2003 - 2006


GeoCLEF Monolingual English



Variabilität

- **BEOBACHTUNG:** Der Unterschied in der Performanz zwischen den Systemen ist wesentlich geringer als zwischen den Topics


Beispiel GeoCLEF 2006



Varianz **der Systeme** in GeoCLEF 2006

Mandl 2008

Beispiel GeoCLEF 2006




Varianz **der Topics** in GeoCLEF 2006

Mandl 2008

Aggregation mehrerer Anfragen

- i.d.R. einfacher
arithmetischer Durchschnitt

Welches System ist besser?



2 Systeme, 3 Anfragen

„IR Psychologie“


«The **unhappy customer**, on average, **will tell 27** other people ...»

«**Dissatisfied customers tell** an average of **ten** other people about their bad experience. Twelve percent tell up to twenty people.»

→ ***Bad news travels fast.***

Credit to Jacques Savoy for slide

„IR Psychologie“



On the other hand, satisfied customers will tell an average of *five* people about their positive experience.

→ ***Good news travels somewhat slower***

Eine Site-Suche sollte robust funktionieren

Ausreisser nach unten müssen vermieden werden!

für jede Anfrage

für jedes Bewertungskriterium


Credit to Jacques Savoy for slide



„IR Psychologie“

- Sehr gute Ergebnisse, schlechte Interaktion
 - -> Unzufriedener Benutzer
- Sehr gute Interaktion, schlechte Ergebnisse
 - -> Unzufriedener Benutzer

GMAP



Robustheit

- Stabile Performanz über alle Anfragen anstatt hohe durchschnittl. Performanz
- “Schwierige” Anfragen gewinnen größeres Gewicht bei der Evaluierung

NTCIR



- Mehrsprachiges Retrieval für asiatische Sprachen
- Durchgeführt in Tokio
 - National Institute for Informatics
- Tasks
 - Cross-lingual
 - Chinesisch, Japanisch, Koreanisch -> Englisch
 - Patent-Retrieval
 - Web-Retrieval
 - Question Answering



FIRE

- Evaluierungsinitiative für Indische Sprachen
 - Hindi und Bengali (gehören zu den 10 meist gesprochenen Sprachen der Welt)
 - Marathi, Tamil, Telugu, Punjabi, Malayalam
 - Englisch
- Zeitungstexte
- Läuft seit 2008
- <http://www.isical.ac.in/~clia/>

INEX



- Initiative for the Evaluation of XML Retrieval
 - Evaluierung von Retrieval mit strukturierten Dokumenten
 - Ziel: nicht das gesamte Dokument, sondern den kleinsten relevanten Ausschnitt finden
 - Ausnutzen der Struktur
 - Testkollektion 2005: Reiseführer
 - <http://inex.is.informatik.uni-duisburg.de:2004/>

IMIRSEL

- International Music Information Retrieval Systems Evaluation Laboratory Project
 - Beantwortung von Fragen zu Musikstücken
- <http://www.music-ir.org/evaluation/>

Benutzer?

- Der Benutzer ist nie in der Rolle der Evaluierenden
- Führt eine Verbesserung der Systeme hinsichtlich der traditionellen Kennzahlen auch zu einer höheren Benutzerzufriedenheit?
- Führt ein gutes Ranking auch zu einer höheren Benutzerzufriedenheit?

Benutzerzufriedenheit

- Bei mehreren Bild-Retrieval Systemen konnte kein Zusammenhang zwischen Präferenz und Qualität erkannt werden
 - Zwei Aufgaben
 - Elf Testpersonen

Maskari et al. 2006

Einwand Benutzerzufriedenheit

- Für einfache Suchaufgaben und kontrollierte Retrieval-Qualität ergab sich kein Effekt auf die Performanz der Benutzer für ein System
 - Künstlich werden unterschiedlich gute Systeme geschaffen (versch. MAP)
 - In 5 Minuten sollten so viele relevante Dokumente wie möglich gefunden werden
 - Ca. 20 Testpersonen
- Turpin & Scholer 2006*
- Systemunterschiede lassen sich bei Benutzertests nicht nachweisen Turpin & Hersch 2001
 - Modell für TREC und CLEF ist der „dedicated searcher“

Einwand Benutzerzufriedenheit

- Für einfache Suchaufgaben und kontrollierte Retrieval-Qualität ergab sich kein Effekt auf die Performanz der Benutzer für ein System
 - Künstlich werden unterschiedlich gute Systeme geschaffen (versch. MAP)
 - In 5 Minuten sollten so viele relevante Dokumente wie möglich gefunden werden
 - Ca. 20 Testpersonen
- Turpin & Scholer 2006*
- Systemunterschiede lassen sich bei Benutzertests nicht nachweisen Turpin & Hersch 2001
 - Modell für TREC und CLEF ist der „dedicated searcher“

Einwand Benutzerzufriedenheit

- Für einfache Suchaufgaben und kontrollierte Retrieval-Qualität ergab sich kein Effekt auf die Performanz der Benutzer für ein System
 - Künstlich werden unterschiedlich gute Systeme geschaffen (versch. MAP)
 - In 5 Minuten sollten so viele relevante Dokumente wie möglich gefunden werden
 - Ca. 20 Testpersonen
- Turpin & Scholer 2006*
- Systemunterschiede lassen sich bei Benutzertests nicht nachweisen Turpin & Hersch 2001
 - Modell für TREC und CLEF ist der „dedicated searcher“