

Information Retrieval: Berücksichtigung der Vagheit in Sprache

Ingo Schmitt

Brandenburgische Universität Cottbus

Institut für Informatik

Lehrstuhl für Datenbank- und Informationssysteme



Gliederung

3.1 Ein einführendes Beispiel

3.2 Stoppworteliminierung

3.3 Stamm- und/oder Grundformreduktion

3.4 Mehrwortgruppenidentifikation

3.5 Terminologische Kontrolle

3.6 Ein sprachunabhängiger Ansatz

3.7 Auszeichnung mittels Metadaten

Je nach Sprache
unterschiedlicher
Aufwand

Begrifflichkeiten

- Wort
 - starker Bezug zur „Zeichenkette“
 - bezieht sich damit eher auf die syntaktische Ebene
- Begriff, Term
 - adressiert stärker die Bedeutung
 - aus dem Englischen kommend „Term“
- Konzept
 - drückt stärkeren Bezug zur Semantik aus
 - entspricht in der Regel einer Gruppe von Wörtern, die sehr inhaltsverwandt sind und hinter denen ein inhaltliches Konzept steht.
 - Beispiel für Konzept
 - »Datenbank«, »Geldinstitut« oder »Bewegung«

3.1 Ein einführendes Beispiel

■ Text:

- »Wirtschaft und Gesellschaft befinden sich derzeit im größten Umbruch seit der Industrialisierung. Die Ursache hierfür liegt in der globalen Verfügbarkeit leistungsfähiger und zugleich kostengünstiger Informations- und Kommunikationstechnologien. Das Informationszeitalter wird Realität.«

■ mögliche Repräsentation (Set of words):

Mehrwortgruppenidentifizierung

- befinden, Das, der, derzeit, Die, Gesellschaft, globalen, größten, hierfür, im, in, Industrialisierung, Informations-, Informationszeitalter, Kommunikationstechnologien, kostengünstiger, leistungsfähiger, liegt, Realität, seit, sich, Umbruch, und, Ursache, Verfügbarkeit, wird, Wirtschaft, zugleich

Stoppworteliminierung

Stammform- oder Grundformreduzierung

Synonyme (Ursache, Grund), ... → Thesauri, ...

3.2 Stoppworteliminierung

- Ziel:
 - Terme, die nicht zur „Semantik“ der Dokumente beitragen, nicht zu verwalten.
- Erzielte Effekte:
 - Reduzierung des Speicherplatzbedarfs
 - Damit auch Verbesserung der Performance der Matchingalgorithmen
 - Verbesserung von Recall und Precision (z.B. im Vektorraummodell)
- Ansätze zur Umsetzung:
 - Führen einer Stoppwortliste
 - Eliminierung hoch- und niedrigfrequenter Begriffe

Stoppwortliste Englisch Bsp. (571 Wörter):

a a's able about above according accordingly across actually after afterwards again against ain't all allow allows almost alone along already also although always am among amongst an and another any anybody anyhow anyone anything anyway anyways anywhere apart appear appreciate appropriate are aren't around as aside ask asking associated at available away awfully b be became because become becomes becoming been before beforehand behind being believe below beside besides best better between beyond both brief but by c c'mon c's came can can't cannot cant cause causes certain certainly changes clearly co com come comes concerning consequently consider considering contain containing contains corresponding could couldn't course currently d definitely described despite did didn't different do does doesn't doing don't done down downwards during e each edu eg eight either else elsewhere enough entirely especially et etc even ever every everybody everyone everything everywhere ex exactly example except f far few fifth first five followed following follows for former formerly forth four from further furthermore g get gets getting given gives go goes going gone got gotten greetings h had hadn't happens hardly has hasn't have haven't having he he's hello help hence her here here's hereafter hereby herein hereupon hers herself hi him himself his hither hopefully how howbeit however i i'd i'll i'm i've ie if ignored immediate in inasmuch inc indeed indicate indicated indicates inner insofar instead into inward is isn't it it'd it'll it's its itself j just k keep keeps kept know knows known l last lately later latter latterly least less lest let let's like liked ...

<http://members.unine.ch/jacques.savoy/clef/englishST.txt>

Stoppwortliste Deutsch Bsp. (603 Wörter):

a ab aber aber ach acht achte achten achter achtet ag alle allein allem allen aller allerdings alles
 allgemeinen als als also am an andere anderen andern anders au auch auch auf aus ausser außer
 ausserdem außerdem b bald bei beide beiden beim beispiel bekannt bereits besonders besser
 besten bin bis bisher bist c d da dabei dadurch dafür dagegen daher dahin dahinter damals damit
 danach daneben dank dann daran darauf daraus darf darfst darin darüber darum darunter das das
 dasein daselbst dass daß dasselbe davon davor dazu dazwischen dein deine deinem deiner dem
 dementsprechend demgegenüber demgemäss demgemäß demselben demzufolge den denen
 denn denn denselben der deren derjenige derjenigen dermassen dermaßen derselbe derselben des
 deshalb desselben dessen deswegen d.h dich die diejenige diejenigen dies diese dieselbe dieselben
 diesem diesen dieser dieses dir doch dort drei drin dritte dritten dritter drittes du durch durchaus
 dürfen dürfte durfte durften e eben ebenso ehrlich ei ei, ei, eigen eigene eigenen eigener eigenes ein
 einander eine einem einen einer eines einige einigen einiger einiges einmal einmal eins elf en ende
 endlich entweder entweder er Ernst erst erste ersten erster erstes es etwa etwas euch f früher fünf
 fünfte fünften fünfter fünftes für g gab ganz ganze ganzen ganzer ganzes gar gedurft gegen
 gegenüber gehabt gehen geht gekannt gekonnt gemacht gemocht gemusst genug gerade gern
 gesagt gesagt geschweige gewesen gewollt geworden gibt ging gleich gott gross groß grosse
 große ...

<http://members.unine.ch/jacques.savoy/clef/germanST.txt>

Probleme mit Stoppwortlisten

- **Erstellungs- und Pflegeaufwand:**
 - Aber: es gibt für alle gängigen Sprachen umfassende Stoppwortlisten
- **Ggf. Anpassung an die Domäne sinnvoll:**
 - Begriff Rechner könnte für Informatikzeitschriften ggf. ein sinnvolles Stoppwort sein


Eliminierung hoch- und niedrigfrequenter Begriffe

- In einem Artikel schlägt Crouch vor [Cro90]:
 - Begriffe, die in weniger als 1% aller Dokumente auftreten, nicht zu betrachten, weil sie **zu spezifisch** sind, und
 - Begriffe, die in mehr als 10% der Dokumente auftreten, nicht zu betrachten, weil sie **zu allgemein** sind.
- Setzt Existenz eines konkreten Datenbestands voraus



Einfluss der Dokumentgröße

Beispiel: Kapitel und Verse des Neuen Testaments der Bibel
relative Anz. der Begriffe, die in
mindestens x % der Dokumente vorkommen



3.3 Stamm- und/oder Grundformreduktion

- Flexionsformen (Beugungen):
 - Konjugation: laufen – lief – gelaufen
 - Deklination: das Haus – des Hauses – die Häuser
- gleicher Wortstamm in verschiedenen Derivationsformen
 - Proben – Erprobung – Probe

Matching sollte sich auf Wortstämme beziehen
⇒ Verbesserung von Recall

Nutzung im Rahmen der Anfragebearbeitung

- Erweiterung der Anfrage oder
- Generelle Abbildung der Terme auf die Grund- oder Stammform



Erweiterung der Anfrage

- sämtliche Wortformen bleiben in der Anfrage erhalten
- Anfrage wird um alle denkbaren Wortformen erweitert.
z.B. per Thesaurus oder Lexikon
- **Vorteil:** Informationsgehalt der Anfrage bleibt vollkommen bestehen
- **Nachteil:** Anfrage kann umfangreich werden
⇒ Performance-Einbußen

Besser ist generelle Abbildung der Terme auf Grund- und Stammform

Abbildung auf die Grund- und Stammform

Reduzierung auf Grund- oder Stammform bei
Umwandlung der Anfragen/Dokumente in die jeweilige
Repräsentation

■ Vorteile:

- reduzierte Zahl der zu verwaltenden Terme
- $\Rightarrow$ Steigerung der Systemperformance
- Rückführung zu Grund- und Stammform ist einfacher als Anfrageerweiterung

Nachteil:

gezielte Suche nach Wortform unmöglich $\Rightarrow$ Precision-Einbuße



Grundformreduktion

- Wörter $\Rightarrow$ *grammatikalische Grundform*
 - Substantive $\Rightarrow$ Nominativ Singular
 - Verben $\Rightarrow$ Infinitiv
- Verfahren: Abtrennen der Flexionsendung und Abbildung auf existierende Wörter

Beispiel: *applies* $\Rightarrow$ *appl* $\Rightarrow$ *apply*

Stammformreduktion

- führt Wörter auf ihren Wortstamm zurück.
- Wortstamm muss kein Wort sein
- Stamm für Verb und entsprechende Substantive ist gleich

Beispiel: *computer, compute, computation, computerization* $\Rightarrow$ *comput*

Bezeichnungen nach Kuhlen

Kuhlen [Kuh77] unterscheidet drei Verfahren zur Grund- und Stammformreduktion:

- Lexikographische Grundform
- Formale Grundform
- Stammform

Lexikographische Grundform

- Form, in der das Wort in einem Wörterbuch zu finden ist
- Rückgängigmachen durch Flexion möglicherweise entstandener graphematischer Veränderungen der Grundform



Formale Grundform

Formale Grundform nach Kuhlen:

*“... Wortfragmente, bei denen die “normalen” englischen und
fremdsprachigen (hauptsächlich lateinischen) Flexionsendungen
abgetrennt werden, ohne dass die entstandenen Wortfragmente
rekodiert würden.”.*

Stammform

Stammform nach Kuhlen:

- Zeichenketten, die durch *Deflexion* und Abtrennen von Derivationsendungen entstehen
- Zeichenketten sollen soweit wie möglich durch *Rekodierung* vereinheitlicht werden



Formale, lexikalische Grundform und Stammform am Beispiel

[illegible]

Verfahren zur Grund- und Stammformreduktion

- Trunkierung
- Regeln
- Wörterbücher

Einsatz ist abhängig von Sprache

- Englisch: schwach flektiert $\Rightarrow$ Regeln
- Italienisch: stärker flektiert $\Rightarrow$ viele Regeln
- Deutsch: Wörterbücher



Verfahren auf Basis einfacher Trunkierung

- Trunkierung explizit in der Anfrage
- beispielsweise in Form von regulären Ausdrücken
 - reguläre Ausdrücke in UNIX (nach [Gul88]) etwa mit *grep*:

Bedeutung:	Metazeichen:
Beliebiges einzelnes Zeichen	.(Punkt)
Beliebige Zeichenkette (auch die leere)	.*
Beliebige Wiederholung des vorangestellten Zeichens (auch keine)	*
Beliebige Wiederholung des vorangestellten Zeichens (mindestens 1)	+
0 oder 1 Wiederholung des vorangestellten Zeichens	?
Eines der Zeichen aus ...	[...]
Eines der Zeichen aus dem Bereich ...	[a-e]
Eines der Zeichen aus den Bereichen ...	[a-eh-x]
Alle Zeichen außer ...	[^...]
Fluchtsymbol	\

Verfahren auf Basis einfacher Trunkierung


- einfache Anfrage mit Trunkierung:

H[aä]us.* AND Finanz.*

- **Nachteile:**

- aufwendige Anfrageformulierung
- syntaktische Regeln der natürlichen Sprache werden nicht unterstützt

Un*x-Tool *grep*

A terminal window titled "Terminal — bash — 130x24" showing the output of a grep command. The command is `grep -c -f atari* ./*.txt` executed in the directory `~/Documents/Bilddatenbanken/consollection/_txt/`. The output lists various Atari-related files and their corresponding counts.

```
Terminal — bash — 130x24
david@davids-macbook-pro~/.Documents/Bilddatenbanken/consollection/_txt/: grep -c -f atari* ./*.txt
atari2600b_1.txt:8
atari2600junior_1.txt:8
atari2600juniorb_1.txt:8
atari2600juniors_1.txt:7
atari5200_1.txt:5
atari7800_1.txt:3
./32X_1.txt:1
./3D0FZ1_1.txt:0
./3doblastar_1.txt:0
./3dofz10_1.txt:0
./3dosystem_1.txt:1
./3dotry_1.txt:0
./800xl_1.txt:3
./9015_1.txt:1
./AMIGAcdtv_1.txt:0
./AQUARIUSCONSOLE_1.txt:1
./BLACKPOINTFS2000_1.txt:1
./BSSBILDSCHIRM_1.txt:1
./COLECOVISION_1.txt:4
./DIGICASSE_1.txt:0
./ES2201_1.txt:0
./ES2218_1.txt:0
./FAIRCHILD_1.txt:2
```

Lovins-Algorithmus zur Grundformreduktion

- regelbasierter Algorithmus
- für Texte im Englischen geeignet
- Arbeitet zweistufig
 - Abtrennung der Endungen
 - Transformation der verbliebenen Endungen
- Nicht beste Endung des Wortes wird gefunden
- aber: **Konsistenz**, also Gleichbehandlung aller Wörter

Vorgehen des Lovins-Algorithmus

- Abtrennung der Endungen anhand folgender Tabelle
- Einhaltung von Bedingungen
 - A: keine Bedingung
 - B: verbleibender Wortstamm hat mind. 3 Zeichen
 - C: verbleibender Wortstamm hat mind. 4 Zeichen

Abtrennen von Wortendungen

Länge	Endung	Bedingung
11	alistically	B
	arizability	A
	izationally	B
10	antialness	A
	arisations	A
	arizations	A
	entialness	A
9	allically	C
	antaneous	A
4	able	A
	ably	A
	ages	B
	ally	B
3	ism	B
1	e	A

Vorgehen des Lovins-Algorithmus

weitere Schritte:

- Falls Wort mit s endet und davor kein s
⇒ Entferne das s
 - *stems* wird zu *stem*
 - aber *stress* bleibt *stress*



Vorgehen des Lovins-Algorithmus

weitere Schritte:

- Falls Wort mit es endet
⇒ Entferne das abschließende s
 - *places* wird zu *place*
 - *Likes* wird zu *like*
 - *Theses* wird zu *these* (Fehler!)
 - *Indices* wird zu *indice* (Fehler!)
 - *Syntheses* wird zu *synthese* (Fehler!)

Problem: Wörter griechischen Ursprungs mit Singularform
-is (Pluralform -es)

Vorgehen des Lovins-Algorithmus

weitere Schritte:

- Überführe *iev* zu *ief* und *metr* zu *meter*
 - *Believable* wird zu *believ* und nun zu *belief*



Vorgehen des Lovins-Algorithmus

weitere Schritte:

- Falls Wort mit *ing* endet und davor mehr als ein Buchstabe und kein *th*
⇒ Lösche das *ing*
 - *thinking* wird zu *think*
 - *singing* wird zu *sing*
 - *sing* wird zu *sing* (keine Änderung)
 - *thing* wird zu *thing* (keine Änderung)
 - *preceding* wird zu *preced* (**Fehler**; kein Wort)
- Fehlerbehebung: Wenn Wort nach Reduktion auf *et*, *ed*, *es* endet ⇒ e *anhängen*



Vorgehen des Lovins-Algorithmus

weitere Schritte:

- Falls Wort mit *ed* endet, davor Konsonant und davor mindestens 1 Buchstabe
⇒ Lösche das *ed*
 - *ended* wird zu *end*
 - *red* wird zu *red*
 - *proceed* wird zu *proceed*
 - *proceeded* wird zu *proceed*

Vorgehen des Lovins-Algorithmus

weitere Schritte:

- Falls nach Entfernen der Endung ein Wort mit *bb*, *dd*, ..., *tt* endet
⇒ Entferne einen der doppelten Buchstaben
 - *embedded* wird zu *embedd* und nun zu *embed*

Vorgehen des Lovins-Algorithmus

weitere Schritte:

- Falls Wort mit mehr als 5 Buchstaben auf *ion* endet: $\Rightarrow$ Entferne *ion*
- Sofern letzter Buchstabe des Stammes Konsonant und vorhergehender Vokal $\Rightarrow$ füge zusätzlich *e* an
 - *direction* wird zu *direct*
 - *polution* wird zu *polute*
 - *plantation* wird zu *plantate* (*Fehler!*)
 - *zion* wird zu *zion*
 - *scion* wird zu *scion*
 - *cation* wird zu *cate* (*Fehler, da cation ist Kunstwort*)



Lovins-Algorithmus


Fazit:

- Englische Sprache braucht ca. 10 bis 20 Regeln
- Ausnahmen für irreguläre Verben notwendig
- Regeln sollten iterativ anwendbar sein
 - *directions* wird zu *direction* wird zu *direct*

Betrachtung von Vorsilben

Vorsilben sollten nicht entfernt werden

- Beispiel: obwohl gleicher lateinischer Stamm, drückt Vorsilbe unterschiedliche Semantik aus



Weitere regelbasierte Algorithmen

- Algorithmus von Porter [Por80]
 - Sehr häufig eingesetzt
 - Gleiche Idee wie Lovins-Algorithmus
 - Aber komplexere Regeln
 - z.B. in Textsuche von PostgreSQL 8.4
- Weitere Stemming-Algorithmen für Englisch verfügbar, etwa *Lancaster Stemming Algorithm*
- Martin Porters Projekt mit fertigen Algorithmen und Framework zur Eigenentwicklung
 - <http://snowball.tartarus.org/>

Verfahren, die auf Wörterbüchern basieren

- Regelbasierte Verfahren nur für schwach flektierte Sprachen wie Englisch
- für stark flektierte Sprachen (deutsche Sprache)
⇒ Wörterbuch
 - Flexionsform → Grundform
 - *lief* → *laufen*
 - *Häuser* → *Haus*
 - Derivationsform → Grundform
 - *Lieblosigkeit* → *lieblos*
 - *Berechnung* → *rechnen*

Problem: Pflege des Wörterbuchs, Fachvokabular oft nötig

3.4 Mehrwortgruppenidentifikation

- Suche nach „Bundeskanzlerwahl“
- Dokument enthält aber „die Wahl des Bundeskanzlers“
- Was ist mit Dokument „... die Wahl des Bundeskanzlers fiel auf Saumagen mit Kraut ...“?

Ansätze zur Mehrwortgruppenidentifikation im Deutschen

- Ignorieren des Problems, d.h. Reduktion auf Grund- und Stammform reicht
 - Terme sind etwa „Wahl“, „Bundeskanzler“ und „Bundeskanzlerwahl“
 - Problem: Suche nach „Wahl“ in Dokument „Bundeskanzlerwahl“ nicht erfolgreich
⇒ Recall leidet
- Zerlegen zusammengesetzter Wörter in Bestandteile
 - Recall steigt
 - Suche nach „Bundeskanzlerwahl“ faktisch unmöglich

Ansätze zur Mehrwortgruppenidentifikation im Englischen

- Keine zusammengesetzten Wörter vorhanden
- Damit sind Worte bereits zerlegt
 - *Mehrwortgruppen (compound terms, phrases)* tragen eigene Bedeutung
 - z.B. „Information Retrieval“ oder „Artificial Intelligence“
⇒ Precision leidet

Ermittlung von Mehrwortgruppen im Englischen


■ 1. Ansatz

- Mehrwortgruppe: Wörter A und B mit maximal n Wörtern dazwischen
- Verfeinerung: Berücksichtigung von Reihenfolge und Satzgrenzen
- Achtung: „college junior“, „junior college“ und „junior in college“ tragen völlig unterschiedliche Bedeutungen

Ermittlung von Mehrwortgruppen im Englischen

- 2. Ansatz (Natural Language Processing):
 - Parser ermittelt grammatikalische Satzstruktur
 - Probleme:
 - Nicht alle Sätze sind zur Grammatik konform
 - Komplexe Satzformen
 - Aufwand der Algorithmen
- Trotzdem existieren praktisch einsetzbare Parser, siehe etwa in [Str94]

Weizenbaums ELIZA (1966)



<http://bs.cyty.com/menschen/e-etzold/archiv/science/rat.htm>

Mehrwortgruppen – Identifikation im Darmstädter Indexierungsansatz

einfaches, robustes Verfahren zur Identifikation von Mehrwortgruppen [Lus86]

- Nur für Deutsch (Beispiel aber in Englisch)
- Ausgangspunkt ist Mehrwortgruppen-Wörterbuch
 - Durch Analyse zahlreicher Texte automatisch gewonnen
 - Lange Wörter wurden identifiziert und dann zerlegt
- Analyse des Textes
 - Auftreten einer Komponente einer Mehrwortgruppe
⇒ Test ob restliche Komponente innerhalb Maximalabstand

Mehrwortgruppen – Identifikation im Darmstädter Indexierungsansatz

Kriterien zur Beschreibung der Form einer Mehrwortgruppe:

1. Abstand zwischen Komponenten (alle Wörter, nur Stoppwörter oder nur relevante Wörter)
2. Reihenfolge der Komponenten
3. Komponenten im gleichen Satz
4. Für jede Komponente: Gleichheit bzgl. Grundform oder Stammform

⇒ Wahrscheinlichkeit syntaktisch korrekter Identifikation von Mehrwortgruppe abschätzbar

Experimentelle Untersuchungen haben ergeben, dass von den genannten Merkmalen nur das erste und vierte die Identifikationssicherheit signifikant beeinflusst



Mehrwortgruppen – Identifikation im Darmstädter Indexierungsansatz

Beispieltext:

Identifizierte Kompon.:

- TUNNEL JUNCTION
- TUNNEL CURRENT
- ELECTRICAL
CONDUCTIVITY
- ALUMINIUM
SUBSTRATES
- MEASURE ELECTRICAL
- FILM COEFFICIENT

Die ersten drei korrekt, restliche falsch

Current-voltage spectra of metal/oxide/SnTe diodes.
Pt. 1

In metal/oxide/SnTe tunnel junctions (where the oxide is Al_2O_3 or SiO_2 and the metal is lead or aluminium) on BaF_2 or $NaCl$ substrates the tunnel current $I(U)$ and its derivatives $I'(U)$ and $I''(U)$ were measured at 4.2 K. Additionally the Hall coefficient and electrical conductivity of the monocrystalline SnTe films were determined at the same temperature. The pronounced oscillations in I'' suggest the existence of a quantum size effect in the very thin SnTe films in several cases, although this is complicated by various other processes. The most important features of the different types are discussed briefly.

Abbildung 3.3 — Ein Beispieltext.

Ein Nachsatz zur Begriffswelt

Präkombination, Präkoordination und Postkoordination

■ Präkombination:

bereits in Indexierungssprache sind Begriffsverknüpfungen abgelegt, etwa "Halswirbelfraktur" oder "Europäischer Binnenmarkt"

■ Präkoordination:

Verknüpfung im Zuge der Indexierung bei der Erstellung der Repräsentationen, etwa "Halswirbel" + "Fraktur" $\Rightarrow$ "Halswirbelfraktur"

■ Postkoordination:

Verknüpfung, die während der Suche mittels Boolescher oder sonstiger Operatoren gebildet werden, etwa "Europa UND Binnenmarkt"

3.5 Terminologische Kontrolle

- stammt aus dem Bibliothekswesen
- Ziel: Vermeidung Mehrdeutigkeit durch „eindeutige“ Begriffsverwendung
- **manuelle Indexierung**: zweistufiger Prozess
 1. Erkennen der wieder auffindbar zu machenden Essenz eines Textes
 2. Wiedergeben dieser Essenzen in ausreichender Form
- Verwendung künstlicher Sprache mit eindeutiger **Vorzugsbenennung**.

Terminologische Kontrolle

Indexierungssprache:

- künstliche Sprache
- dient zum Wiedergeben der Essenz eines Textes
- **Deskriptoren**: Elemente der Indexierungssprache
- **Terminologiekontrolle**: Regeln und Aktivitäten, die einen Deskriptor eindeutig definieren und Mehrdeutigkeiten und Unklarheiten ausschalten

Synonymkontrolle


- Zusammenfassung von Bezeichnungen zu Äquivalenzklassen
- Arten von Synonymen:
 - Schreibweisenvarianten: „Friseur“, „Frisör“ oder „UN“, „UNO“, „Vereinte Nationen“
 - unterschiedliche Konnotationen, Sprachstile, Verbreitungsgebiete: „Telefon“, „Fernsprecher“ oder „Pferd“, „Gaul“ oder „Myopie“, „Kurzsichtigkeit“
 - Quasi-Synonyme: „Schauspiel“, „Theaterstück“ oder „Rundfunk“, „Hörfunk“
- Deskriptor (Vorzugsbenennung): „Ross“, „Gaul“, „Mähre“, „Klepper“, „Pferd“ $\Rightarrow$ „Pferd“

Synonymkontrolle

Einsatz von Thesauri

- Äquivalenzklassen von Synonymen und
- Begriffen mit geringen oder irrelevanten Bedeutungs differenzen
 - unterschiedliche Spezifität:
„Sprachwissenschaft“ und „Linguistik“
 - Antonyme: „Härte“ und „Weichheit“
 - spezieller Unterbegriff: „Winterweizen“ und „Weizen“
 - Gleichsetzung von Verb und Substantiv: „wohnen“ und „Wohnung“

Allgemeiner Thesaurus



Polysemkontrolle

Aufteilung mehrdeutiger Bezeichnungen auf mehrere Äquivalenzklassen

- **Homographen**: Unterscheidung nach *sprachlicher Betonung*
"T**e**nor" im Sinne von "Haltung, Inhalt, Sinn, Wortlaut" und
"Ten**o**r" im Sinne von "hohe Männerstimme"
- **Polyseme**: Unterscheidung nach dem *Kontext*
"Bank" im Sinne von "Sitzgelegenheit" aber auch "Geldinstitut"

Morphologische Zerlegung

Morphologische Zerlegung: Zerlegung Mehrwortgruppen in ihre Wortbildungselemente, sogenannte **Morpheme**

- "Abfallbeseitigung" $\Rightarrow$ "Abfall" UND "Beseitigung"
- "Krankenhausbibliothek" $\Rightarrow$ "Krankenhaus" UND "Bibliothek"

Manchmal Zerlegung nicht sinnvoll:

- "Handschuh", "Eisenbahn"

Semantische Zerlegung: Zerlegung in begriffliche Einheiten, welche Ausgangsbegriff reproduzieren

- "Eisenbahn" $\Rightarrow$ "Schienenverkehr" UND "Überlandverkehr"
- "Handschuh" $\Rightarrow$ "Hand" UND "Bekleidung"

Thesaurus

[Kom75] definiert einen Thesaurus wie folgt:

Ein Thesaurus ist eine natürlich-sprachlich basierte Dokumentationssprache, die die umkehrbar eindeutige Zuordnung von Begriffen und Bezeichnungen der natürlichen Sprache anstrebt, indem sie vollständige Vokabularkontrolle und terminologische Kontrolle ausübt und die Begriffe sowie Relationen zwischen ihnen durch Darstellung von Relationen zwischen den Bezeichnungen und gegebenenfalls zusätzliche Hilfsmittel darstellt.

Deskriptor

Calvin Mooers führte 1956 Konzept des Deskriptors ein:

- Repräsentant einer Wortfamilie bzw. Begriffs
- Festlegung der Bedeutung per Definition
- Gültigkeit nur innerhalb eines Systems



Thesaurusrelationen

- Thesaurusrelation: Beziehung zwischen Wörtern in einem Thesaurus
- nach DIN 1643-1 drei Grundtypen:
 1. Äquivalenzrelation: Beziehungen zwischen wirklichen Synonymen
 2. Hierarchierelation:
 1. Abstraktionsrelation (generische Relation, etwa „LKW ist ein Kraftfahrzeug“)
 2. Bestandsrelation (partitive Relation, etwa „ein PKW besteht aus Motor, ...“)
 3. Assoziationsrelation: bezeichnen verwandte Begriffe, etwa „SQL“ und „Datenbanken“



Thesaurusrelationen

Kurzzeichen		Bedeutung
Deutsch	Englisch	
TT	TT	Top Term (Kopfbegriff einer Hierarchie)
OB	BT	übergeordneter Begriff
UB	NT	untergeordneter Begriff
VB	RT	verwandter Begriff (Assoziationsrelation)

Tabelle 3.4 — In einem Thesaurus zu verwaltende Relationen, wenn man zwischen Abstraktions- und Bestandsrelationen nicht unterscheiden will

B für *broader*, N für *narrower*, T für *term*, G für *generalization*,
P für *participation*



Thesaurusrelationen

Kurzzeichen		Bedeutung
Deutsch	Englisch	
OA	BTG	Oberbegriff (Abstraktionsrelation)
UA	NTG	Unterbegriff (Abstraktionsrelation)
SP	BTP	Verbandsbegriff (Bestandsrelation)
TP	NTP	Teilbegriff (Bestandsrelation)

Tabelle 3.5 — Aufteilung der Relationen OB und UB, wenn man zwischen Abstraktions- und Bestandsrelationen unterscheiden will



Nutzung eines Thesaurus in einem IR-System

- Anfrageerweiterung
 - ⇒ höherer Recall-Wert, schlechterer Precision-Wert
 - ⇒ sollte für Nutzer optional sein
- Erstellung der Dokumentenrepräsentation
 - Verwendung der Vorzugsbenennungen
 - ⇒ reduzierter Speicherplatzbedarf
 - ⇒ höherer Recall-Wert, evtl. schlechterer Precision-Wert

3.6 Ein sprachunabhängiger Ansatz

- Problem bei Ansätzen zur *Grund- und Stammformreduktion*, zur *Mehrwortgruppenbetrachtung*: feste Bindung an Sprache
⇒ neue Sprache erfordert Anpassung
- Sprachunabhängiger Ansatz: **n-grams**
 - für Trigrams ($n = 3$): *Eisenbahn* ⇒ *eis, ise, sen, enb, nba, bah, ahn*
 - für Bigrams ($n = 2$): *Eisenbahn* ⇒ *ei, is, se, en, nb, ba, ah, hn*
 - Manchmal auch mit Wortgrenze:
Eisenbahn ⇒ *#ei, is, se, en, nb, ba, ah, hn#*

Evaluierung von n-grams

- n -grams zur Indexierung statt Wörter
- 3 prinzipielle Ansätze beim Vektorraummodell
 1. Wörter als Terme (= Dimensionen des Vektorraumes)
 2. Stammformen als Terme
 3. 5-grams als Terme
Schritte: Interpunktion entfernen, Umwandlung in Klein-buchstaben, Abbildung Zahlen auf einziges Zeichen

Evaluierung von n-grams

- TREC-Untersuchung:
 - Kurze Anfragen $\Rightarrow$ Wörter und Stammformen als Terme besser als 5-grams
 - Lange Anfragen $\Rightarrow$ 5-grams besser
- Problem: Erklärung des Suchergebnisses auf Grundlage von n-grams unmöglich

3.7 Auszeichnung mittels Metadaten

- Reduzierung der Vagheit der natürlichen Sprache mittels Metadaten
- Spezielle Felder für Dokument etwa für *Titel, Verfasser, Erstellungsdatum*
- Beispiele:
 - Dublin Core
 - Semantic Web

Dublin Core

- **Dublin Core Metadata Initiative** (DCMI): 1995 gegründet in Dublin, Ohio auf Workshop organisiert von *Online Computer Library Center* (OCLC) und dem *National Center for Supercomputing Applications* (NCSA)
- Ziel:
 - Entwicklung eines standardisierten *Metadatensatzes* zur Beschreibung von digitalen Dokumenten
 - Allgemein verständliche Semantik und erweiterbar
 - Erstellung der Metadaten durch Autoren

Auszeichnung mittels Metadaten

- Der Kernsatz von Dublin Core: 15 Elemente
- Elemente sind optional und können zudem wiederholt aufgeführt werden

Element	Beschreibung
Title	Titel der Quelle; der vom Verfasser, Urheber oder Verleger vergebene Name der Ressource.
Creator	Die Person(en) oder Organisation(en), die den intellektuellen Inhalt verantworten. Z.B. Autoren bei Textdokumenten; Künstler, Photographen bzw. auch andere Bezeichnungen wie Komponist und Maler bei graphischen Dokumenten.
Subject	Thema, Schlagwort, Stichwort. Das Thema der Ressource bzw. Stichwörter oder Phrasen, die das Thema oder den Inhalt beschreiben.
Description	Eine textliche Beschreibung des Ressourceninhalts inklusive einer Kurzfassung (Abstract) bei dokumentähnlichen Ressourcen oder Inhaltsbeschreibungen bei graphischen Ressourcen.
Publisher	Die Einrichtung, die verantwortet, dass diese Ressource in dieser Form zur Verfügung steht, wie z.B. ein Verleger, ein Herausgeber, eine Universität oder ein Unternehmen.
Contributors	Zusätzliche Person(en) und Organisation(en), die einen bedeutsamen intellektuellen Beitrag zur Ressource geleistet haben.
Date	Das Datum, an dem die Ressource in der gegenwärtigen Form zugänglich gemacht wurde, bspw. 20021201 für den 01. Dezember 2002.
Type	Die Art der Ressource, z.B. Homepage, Roman, Gedicht, Arbeitsbericht, technischer Bericht, Essay oder Wörterbuch.
Format	Hier wird das datentechnische Format der Ressource eingetragen, z.B. Text/HTML, JPEG-Bilddatei etc.
Identifier	Hier wird eine Zeichenkette oder Zahl eingetragen, die diese Ressource eindeutig identifiziert. Beispiele für vernetzte Ressourcen sind URLs.
Source	In diesem Element wird – falls nötig – das gedruckte oder elektronische Werk, aus dem diese Ressource stammt, eingetragen.

Auszeichnung mittels Metadaten

Language	Hier werden die Sprache(n) des intellektuellen Inhalts der Ressource vermerkt.
Relation	Die Angabe in diesem Feld ermöglicht es, Verbindungen zwischen verschiedenen Ressourcen darzustellen, die einen formalen Bezug zueinander haben, aber als eigenständige Ressourcen existieren. Beispiele sind Bilder in einem Dokument, Kapitel eines Buches oder Einzelstücke einer Sammlung.
Coverage	Hier werden Angaben zur räumlichen Bestimmung (z.B. geographische Koordinaten) und zeitlichen Gültigkeit eingetragen, die die Ressource charakterisieren.
Rights	Vorgesehen für den Inhalt dieses Elements ist ein Link (z.B. über eine URL) zu einem Urhebervermerk, ein »Rights-Management«-Vermerk über die rechtlichen Bedingungen oder ggf. ein Link zu einem Server, der solche Informationen dynamisch erzeugt.

Auszeichnung mittels Metadaten

Angabe etwa im Head-Block einer HTML-Datei:

```
<html>
  <head>
    <title>A Dirge</title>
    <link rel="schema.DC"
          href="http://purl.org/DC/elements/1.0/">
    <meta name="DC.Title" content="A Dirge">
    <meta name="DC.Creator" content="Shelley, Percy Bysshe">
    <meta name="DC.Type" content="poem">
    <meta name="DC.Date" content="1820">
    <meta name="DC.Format" content="text/html">
    <meta name="DC.Language" content="en">
  </head>
```




Auszeichnung mittels Metadaten

Semantic Web

- Begriff von Tim Berners-Lee
- Ziel: Erweiterung von WWW, um Dokumentsemantik besser durch Algorithmen erfassen zu können
⇒ bessere Suche, besserer Dokumentenaustausch
- Realisierung:
 - Anreicherung von Inhalten mittels maschinenverständlicher Metadaten
 - Schichtenarchitektur
- *Standardisierung durch World Wide Web Consortium (W3C)*

Auszeichnung mittels Metadaten Semantic Web



Auszeichnung mittels Metadaten Semantic Web

- Unicode: Standard mit Schriftzeichen für viele Sprachen
- URI (*Uniform Resource Identification*): einheitliche Adressierung
- RDF (*Resource Description Framework*): Repräsentation der Metadaten auf Basis von XML
- Ontologie:
 - Beziehung/Regeln zwischen einzelnen Elementen
 - W3C: OWL (*Web Ontology Language*)
- Logic: maschinelles Schließen auf Metadaten
- Trust und Proof: Herstellung von Vertrauenswürdigkeit mittels Signaturen und Verschlüsselung

RDF-Modell

- allgemeine Sprache für Metadaten für WWW-Ressourcen
- Ressourcen: Dokumente, Bilder, beliebige Objekte etwa Waren mit Preis und Verfügbarkeit
- Beispiel: *Die Webseite <http://ail.inf.uni-bayreuth.de/> hat einen *Autor*, dessen Name *Andreas Henrich* ist.*
 - URL zur Identifikation einer Ressource $\Rightarrow$ *Subject*
 - *Autor* als Eigenschaft (Attribut) $\Rightarrow$ *Predicate*
 - *Andreas Henrich* als Attributwert $\Rightarrow$ *Object*

RDF-Modell

Überführung natürlichsprachlicher Aussage in maschinenverständliches Format benötigt:

- maschinenverständliche Identifikatoren für Subject, Predicate und Object
- Maschinell lesbares Format für Identifikatoren

⇒ Uniform Resource Identifier (URI)

Uniform Resource Identifier (URI)

- URL für Webseiten als Untermenge von URI
- URI zur eindeutigen Identifizierung beliebiger Objekte
- RDF: URI für Subject, Predicate und Object

RDF - Modell


- Beispiel: Die Webseite <http://ai1.inf.uni-bayreuth.de/> hat einen *Autor*, dessen Name *Andreas Henrich* ist.

- Bestandteile identifiziert durch URI
 - **Subject**: <http://ai1.inf.uni-bayreuth.de/>
⇒ URL
 - **Predicate**: <http://purl.org/dc/elements/1.1/creator>
⇒ Verwendung von Dublin Core
 - **Object**: <http://ai1.inf.uni-bayreuth.de/mitarbeiter/henrich/>
⇒ Homepage von Andreas Henrich

RDF – Modell als Graph

RDF-Aussagen als Knoten und Kanten in einem Graphen


- Knoten: Subject und die Object durch Knoten
- Benannte und gerichtete Kante: Predicate



RDF – Modell als Graph


- Sammlung von Aussagen, etwa
 - Webseite <http://ai1.inf.uni-bayreuth.de/> hat Autor, dessen Name Andreas Henrich ist
 - Webseite <http://ai1.inf.uni-bayreuth.de/> hat Erstellungsdatum mit Wert 1.10.2001
 - Webseite <http://ai1.inf.uni-bayreuth.de/> hat als Sprache den Wert Deutsch
- Gemeinsamer Graph von Knoten und Kanten

RDF – Modell als Graph



- Wert als **Literal** und nicht als URI
- Object einer Aussage kann Subject anderer Aussage sein

RDF – Modell als Graph



- zum Autor werden weitere Metadaten angegeben (*Straße, Ort*)
- Autor ist also gleichzeitig Object der einen Aussage und Subject der zweiten Aussage

RDF / XML Syntax Spezifikation

- RDF definiert eine Syntax für die Abbildung der RDF-Graphen in XML
- Knoten und Kanten eines RDF-Graphen werden als Elemente, Attribute, Elementinhalte und Attributwerte in XML abgebildet
- URIs für Eigenschaften und Objekte werden mittels Namensräumen abgebildet

RDF / XML Syntax Spezifikation

■ Beispiel:

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<rdf:RDF xmlns:rdf="http://www.w3c.org/1999/02/22-rdf-syntax-ns#"
  xmlns:dc="http://purl.org/dc/elements/1.1/"
  >

  <rdf:Description rdf:about="http://ai1.inf.uni-bayreuth.de/">
    <dc:date>1.10.2001</dc:date>
    <dc:language>Deutsch</dc:language>
    <dc:creator rdf:resource="http://ai1.inf.uni-bayreuth.de/mitarbeiter/Henrich/" />
  </rdf:Description>
</rdf:RDF>
```

■ Predicate als Element aus Dublin-Core-Modell

RDF / XML Syntax Spezifikation

Erweiterung um lokal definiertes Vokabular ex

```
<?xml version="1.0" encoding="ISO-8859-1"?>
  <rdf:RDF xmlns:rdf="http://www.w3c.org/1999/02/22-rdf-syntax-ns#"
    xmlns:dc="http://purl.org/dc/elements/1.1/"
    xmlns:ex="http://ai1.inf.uni-bayreuth.de/terms/">

    <rdf:Description rdf:about="http://ai1.inf.uni-bayreuth.de/">
      <dc:date>1.10.2001</dc:date>
      <dc:language>Deutsch</dc:language>
      <dc:creator rdf:resource="http://ai1.inf.uni-bayreuth.de/mitarbeiter/Henrich/">
        <ex:street>Universitätsstraße 30</ex:street>
        <ex:city>Bayreuth</ex:city>
      </dc:creator>
    </rdf:Description>
  </rdf:RDF>
```

RDF-Schema

- Mittels RDF-Schema (RDFS) lässt sich ein Typsystem erstellen
- Klassen:
 - ähnlich Klasse in objektorientierten Programmiersprachen
 - Können beliebige Objekte repräsentieren, etwa Webseiten, Personen, Dokumententypen, Dinge oder auch abstrakte Konzepte
 - Unterstützung von Vererbung
- RDF-Schema wird in RDF erstellt

RDF-Schema: Klassen

Im Folgenden werden in RDFS drei Klassen definiert:

- *Automobil*: Basisklasse *Automobil* wird von RDF-Schema-Basisklasse *Resource* abgeleitet
- *Pkw*: Klasse *Pkw* wird von Klasse *Automobil* abgeleitet
- *Sportwagen*: die Klasse *Sportwagen* wiederum von Klasse *Pkw*

RDF-Schema: Klassen

```
<rdf:RDF xmlns:rdf="http://www.w3c.org/1999/02/22-rdf-syntax-ns#"
  xmlns:rdfs="http://www.w3c.org/2000/01/rdf-schema#">

  <rdf:Description rdf:ID="Automobil">
    <rdf:type rdf:resource="http://www.w3c.org/2000/01/rdf-schema#Class"/>
    <rdfs:subClassOf rdf:resource="http://www.w3c.org/2000/01/rdf-schema#Resource"/>
  </rdf:Description>

  <rdf:Description rdf:ID="Pkw">
    <rdf:type rdf:resource="http://www.w3c.org/2000/01/rdf-schema#Class"/>
    <rdfs:subClassOf rdf:resource="#Automobil"/>
  </rdf:Description>

  <rdf:Description rdf:ID="Sportwagen">
    <rdf:type rdf:resource="http://www.w3c.org/2000/01/rdf-schema#Class"/>
    <rdfs:subClassOf rdf:resource="#Pkw"/>
  </rdf:Description>
</rdf:RDF>
```

RDF-Schema: Eigenschaften

Eigenschaften (Predicates) zu den einzelnen Klassen können wie folgt definiert werden:

```
<rdf:RDF xmlns:rdf="http://www.w3c.org/1999/02/22-rdf-syntax-ns#"
  xmlns:rdfs="http://www.w3c.org/2000/01/rdf-schema#">

  <rdf:Description rdf:ID="zugelassenAuf">
    <rdf:type rdf:resource="http://www.w3c.org/1999/02/22-rdf-syntax-ns#Property"/>
    <rdfs:domain rdf:resource="#Automobil"/>
    <rdfs:range rdf:resource="http://ai1.inf.uni-bayreuth.de/classes#Person"/>
  </rdf:Description>

  <rdf:Description rdf:ID="MaxAnzahlPassagiere">
    <rdf:type rdf:resource="http://www.w3c.org/1999/02/22-rdf-syntax-ns#Property"/>
    <rdfs:domain rdf:resource="#Pkw"/>
    <rdfs:range rdf:resource="http://www.w3c.org/2001/XMLSchema#integer"/>
  </rdf:Description>

</rdf:RDF>
```

RDF-Schema

- Eigenschaften (Predicate) haben als Kante Ausgangstyp (domain) und Zieltyp (range)
 - Ausgangstyp:
 - Muss Klasse sein
 - Zieltyp:
 - kann ein Literal
 - aber auch Klasse sein

RDF-Dokument

```
<?xml version="1.0"?>
<rdf:RDF xmlns:rdf="http://www.w3c.org/1999/02/22-rdf-syntax-ns#"
  xmlns:a="http://ai1.inf.uni-bayreuth.de/schemas/autos#">

  <a:Pkw rdf:ID="AndreasHenrichsPkw">
    <a:zugelassenAuf rdf:resource="http://ai1.inf.uni-bayreuth.de/mitarbeiter/henrich"/>
    <a:MaxAnzahlPassagiere rdf:datatype="http://www.w3c.org/2001/XMLSchema#integer">5</a:MaxAnzahlPassagiere>
  </a:Pkw>
</rdf:RDF>
```

Hier Subject mit *rdf:ID* statt *rdf:about* ⇒ referenzierbar mittels

- *Relativer URI: „#AndreasHenrichPKW“*
- *Absoluter URI: „http://ai1.inf.uni-bayreuth.de/parkplatz/#AndreasHenrichPKW“*

RDF-Dokument

```
<?xml version="1.0"?>
<rdf:RDF xmlns:rdf="http://www.w3c.org/1999/02/22-rdf-syntax-ns#"
  xmlns:a="http://ai1.inf.uni-bayreuth.de/schemas/autos#">

  <a:Pkw rdf:ID="AndreasHenrichsPkw">
    <a:zugelassenAuf rdf:resource="http://ai1.inf.uni-bayreuth.de/mitarbeiter/henrich"/>
    <a:MaxAnzahlPassagiere rdf:datatype="http://www.w3c.org/2001/XMLSchema#integer">5</a:MaxAnzahlPassagiere>
  </a:Pkw>
</rdf:RDF>
```

Hier Subject mit *rdf:ID* statt *rdf:about* ⇒ referenzierbar mittels

- *Relativer URI: „#AndreasHenrichPKW“*
- *Absoluter URI: „http://ai1.inf.uni-bayreuth.de/parkplatz/#AndreasHenrichPKW“*

RDF-Dokument

```
<?xml version="1.0"?>
<rdf:RDF xmlns:rdf="http://www.w3c.org/1999/02/22-rdf-syntax-ns#"
  xmlns:a="http://ai1.inf.uni-bayreuth.de/schemas/autos#">

  <a:Pkw rdf:ID="AndreasHenrichsPkw">
    <a:zugelassenAuf rdf:resource="http://ai1.inf.uni-bayreuth.de/mitarbeiter/henrich"/>
    <a:MaxAnzahlPassagiere rdf:datatype="http://www.w3c.org/2001/XMLSchema#integer">5</a:MaxAnzahlPassagiere>
  </a:Pkw>
</rdf:RDF>
```

Hier Subject mit *rdf:ID* statt *rdf:about* ⇒ referenzierbar mittels

- *Relativer URI: „#AndreasHenrichPKW“*
- *Absoluter URI: „http://ai1.inf.uni-bayreuth.de/parkplatz/#AndreasHenrichPKW“*