

Information Retrieval: Alternativen zur globalen Suche

Ingo Schmitt

Brandenburgische Universität Cottbus

Institut für Informatik

Lehrstuhl für Datenbank- und Informationssysteme



Überblick

- Klassifikation
- Cluster-Ansätze (automatische Klassifikation)
- Browsing (Exploratives Suchen)
- Zusammenfassung



6.1 Klassifikation

- Klassifikation: Strukturierung einer schwer überschaubaren Objektmenge (SQL: group by)
- Definition nach Gablers Wirtschaftsinformatik-Lexikon:

„Klassifizierung, Klassifikation, Abstraktionskonzept, das zu einer Einteilung von Dingen und Begriffen führt, die durch gemeinsame Merkmale miteinander verbunden sind. Sowohl aus wissenschaftlicher als auch aus praktischer Sicht dient die Klassifizierung zur Erhöhung der Überschaubarkeit eines beliebigen Arbeitsbereichs.“



Beispiel einer Klassifikation

Menge Studenten klassifiziert nach „Muttersprache“ und
Studiumsabschnitt

- Franzose im Grundstudium
- Deutscher im Grundstudium
- Italiener im Hauptstudium
- Österreicher im Hauptstudium

Beispiel zeigt starken Bezug zu einer konkreten
Anwendung und dass Klassen nicht unbedingt disjunkt
sind



Ziel einer Klassifikation

- Strukturieren der Elemente einer Grundgesamtheit nach **Merkmale**
- Üblicherweise alternative Merkmale möglich
- Beispiel:
 - Einteilung von Dokumenten nach „*Monographien*“, „*Sammelbänden*“, „*Zeitschriftenartikel*“, ...
 - Alternative Merkmale: *Autoren, Seitenzahl, Erscheinungsjahr, behandelte Themen, ...*



Klassifikation und Information Retrieval

- Klassifikation nach Themen
- Allerdings sehr hohe Themenvielfalt
⇒ mehrstufiges Vorgehen, Themenhierarchien oder -bäume
- Einsatz von Klassifikationsschema in Bibliotheken
Ziel: schnelles Auffinden verwandter Titel
- Weitere populäre Beispiele:
 - Stoffgruppen in der Chemie, Taxonomien in der Biologie
 - Stoffgliederungen in Enzyklopädien



TARIC (Zolltarife der EU)

Abschnitt XVI - Maschinen, Apparate, mechanische Geräte und elektrotechnische Waren, Teile davon; Tonaufnahme- oder Tonwiedergabegeräte, Fernseh-Bild- und -Tonaufzeichnungsgeräte oder Fernseh-Bild- und -Tonwiedergabegeräte, Teile und Zubehör für diese Geräte

Kapitel 85 - ELEKTRISCHE MASCHINEN, APPARATE, GERÄTE UND ANDERE ELEKTROTECHNISCHE WAREN, TEILE DAVON; TONAUFNAHME- ODER -WIEDERGABEGERÄTE

Simulationsdatum 30/03/2010

TARIC-Code	Warenbezeichnung
8501	Elektromotoren u
8502	Stromerzeugungs
8503	Teile, erkennbar a
8504	Elektrische Trans Selbstinduktionss
8505	Elektromagnete; I Spannplatten, Sp
8506	elektromagnetisch Elektrische Primä

--- [8522 90 80 81](#) --- optische Laseraufnahmeeinheit für die Wiedergabe optischer Signale von CD oder DVD und die Aufzeichnung optischer Signale auf DVD, bestehend aus zumindest:

- einer Laserdiode,
- einem integrierten Laser-Treiberschaltkreis,
- einem integrierten Photodetektor-Schaltkreis,
- einem integrierten Frontmonitor-Schaltkreis

und einem Stellglied, zur Verwendung beim Herstellen von Waren der Position 8521

--- [8522 90 80 83](#) --- optisches Blu-ray-Abtastgerät, auch beschreibbar, zur Verwendung mit Blu-ray-Discs, DVDs und CDs, mit mindestens:

- Laserdioden mit drei Wellenlängen,
- einem integrierten Photodetektor-Schaltkreis,
- einem integrierten Frontmonitor- (Detektor-) Schaltkreis und
- einen Stellantrieb,

zur Verwendung beim Herstellen von Waren der Unterposition 8521

--- [8522 90 80 84](#) --- Antriebsvorrichtung für Blu-ray Discs, auch beschreibbar, zur Verwendung mit Blu-ray-Discs, DVDs und CDs, mit mindestens:

- einer optischen Abtastvorrichtung mit Laserdioden mit drei Wellenlängen,
- einem Spindelmotor,

Internationale Patentklassifikation IPC

- Erarbeitung seit 1954 – neunbändiges Handbuch zur Klassifikation von eingereichten und akzeptierten Patenten
- Hierarchisches System
- Ebenen:
 - Sektionen
 - Klassen
 - Unterklassen
 - Gruppen
 - Untergruppen



Probleme von Klassifikationen

- Innovative Themen können oft nicht berücksichtigt werden
- Hoher Aufwand für Aufbau und Pflege
- Keine eindeutige Einordnung von interdisziplinären Themen



Sektionen

Sektion	Inhalt
A	Täglicher Lebensbedarf
B	Arbeitsverfahren; Transportieren
C	Chemie; Hüttenwesen
D	Textilien; Papier
E	Bauwesen; Erdbohren; Bergbau
F	Maschinenbau; Beleuchtung; Heizung; Waffen; Sprengen
G	Physik
H	Elektrotechnik



Beispielpfad

Schlüssel	Ebene	Bezeichnung
G	Sektion	Physik
G01	Klasse	Messen; Prüfen
G01R	Unterklasse	Messen elektrischer Größen; Messen magnetischer Größen
G01R 23	Gruppe	Anordnungen zum Messen von Frequenzen; Anordnungen zum Analysieren von Frequenzspektren
G01R 23/16	Untergruppe	Spektralanalyse; Fourier-Analyse



Revisionen der IPC

- Problem: Neuerungen passen häufig nicht gut in Klassifikation
- Daher alle 5 Jahre Revision
- Bisher klassifizierte Patent bleiben in alter Version
- Recherche muss daher ältere Revisionen berücksichtigen



ACM Classification System

The ACM Computing Classification System (1998)

- A. General Literature
 - A.0 GENERAL
 - Biographies/autobiographies
 - Conference proceedings
 - General literary works (e.g., fiction, plays)
 - A.1 INTRODUCTORY AND SURVEY
 - A.2 REFERENCE (e.g., dictionaries, encyclopedias)
 - A.m MISCELLANEOUS
- B. Hardware
 - B.0 GENERAL
 - B.1 CONTROL STRUCTURES AND MICROPROGRAMMING
 - B.1.0 General
 - B.1.1 Control Design Styles
 - Hardwired control [**]
 - Microprogrammed logic arrays [**]
 - Writable control store [**]
 - B.1.2 Control Structure Performance Analysis
 - Automatic synthesis [**]
 - Formal models [**]
 - Simulation [**]
 - B.1.3 Control Structure Reliability, Testing, and Maintenance
 - Diagnostics [**]
 - Error-checking [**]
 - Redundant design [**]

jective evaluation benchmarks. we focus particularly on assessing feedback methods more directly in terms of their goal of identifying the relevant target class with a small number of samples, and show how to compensate for query targets of varying difficulty by measuring efficiency at generalization.

Categories and Subject Descriptors

H.3.3 [Information Storage and Retrieval]: Information Search and Retrieval—*Relevance feedback Retrieval models Selection process Information filtering*; H.3.4 [Information Storage and Retrieval]: Systems and Software—*Performance evaluation (efficiency and effectiveness)*

General Terms

Algorithms; Experimentation; Human factors; Measurement; Performance



Die Dezimalklassifikation

- *Universal Decimal Classification UDC*
- Vereinheitlichung im Bibliothekswesen
- 1876 vom amerikanischen Bibliothekar Malvil Dewey (1851-1931) entwickelt
- Jede Grundwissenschaft identifiziert durch eine Ziffer, etwa 0 für Allgemeines, 1 für Philosophie und Psychologie
- Untergruppen identifiziert durch nächste Ziffer u.s.w.



Beispiel Klassifikationsgruppe 622.33

- 6 für Technologie
- 2 für Technik
- 2 für Bergbautechnik
- 3 für einzelne Bergbauzweige
- 3 für Kohlebergbau

3-er-Gruppen werden mittels Punkt voneinander getrennt



Facettierung

■ UDC-Hilfstafeln

- Einteilung der Dokumente nach Ort, Zeit, Form, Sprache oder auch zur feineren Stoffgliederung
- In Klammern notiert



Beispiele

- Ort: 622(430) für »Bergbautechnik in Deutschland«
- Symmetrische Beziehung zwischen 2 Themen:
621.3:622 die »Elektrotechnik im Bergbau«
- Beziehung: 622+629 klassifiziert »Mining and Metallurgy«
- Intervall mit „/“: [23/28:294.3](540) klassifiziert
»Christianity in relation of Buddhism in India«



Allgemeine Anhängeszahlen

Folgende vorangestellte bzw. umschliessenden Zeichen sind zulässig:

- = Sprache
- (0...) Form
- (...) Ort
- (=...) Rassen und Völker
- »...« Zeit
- .00 Gesichtspunkt
- -05 Person



Verknüpfung von Dezimalklassifikationen

- + Aufzählung mehrerer Sachverhalte
- : symmetrische Beziehung zwischen zwei Sachverhalten
- :: asymmetrische Beziehung zwischen zwei Sachverhalten,
- / Erstreckungszeichen zur Zusammenfassung mehrerer nebeneinander stehender Dezimalklassifikations-Zahlen
- ' Zusammenfassungszeichen zur Bildung neuer Sachverhalte aus der Kombination einzelner Dezimalklassifikations-Komponenten.



Kataloge im Internet

- 2 Ansätze zur Suche im Internet:
 - Suchmaschinen wie *Google*
 - Kataloge wie *Yahoo, Web.de*
- Beide Ansätze meistens parallel
- Ähnlich Bibliothekswesen
- aber räumliche Ordnung von Dokumenten nicht gefordert $\Rightarrow$ Mehrfacheinträge möglich
- Manuelle Pflege der Klassifikation nötig



Arten von Klassifikationshierarchien

- Monoklassifikationshierarchie: eine Klasse darf nur einer anderen Klasse untergeordnet sein $\Rightarrow$ Baum
- Polyklassifikationshierarchie: Unterordnung mehrerer Klassen $\Rightarrow$ Hierarchie



Probleme mit Klassifikationen

- Wegen manueller Erstellung schnelle Alterung
- Daher Inhomogenitäten und Brüche unvermeidbar
- Ziel: möglichst Monoklassifikation



6.2 Cluster-Ansätze

- Automatisierte Einteilung Menge in Teilmengen (Cluster)
 - Elemente innerhalb Cluster sind ähnlich
 - Elemente verschiedener Cluster sind unähnlich
- Große Mengen können damit strukturiert werden
- Unentdeckte Zusammenhänge können sichtbar werden



Cluster-Analyse und Information Retrieval

Beispielhafte Anwendungen

1. Clustering von Dokumenten anhand ihrer Repräsentationen:
 - auf gesamter Kollektion oder
 - auf Ergebnismenge
2. Clustering von Dokumenten anhand anderer Kriterien, etwa Zitaten
3. Clustering von Termen, um Synonyme zu finden



Ähnlichkeitsmaße und Distanzen

- Ähnlichkeit bzw. Abstand (etwa Euklidische Distanz) zwischen Dokumenten
- Dokumentlänge sollte keinen Einfluss haben



Kosinusmaß

Summe über Produkt
aller Terme taucht immer
wieder auf

sim_{D_i, D_j}



$$\sum_{k=1}^t (w_{ik} \cdot w_{jk})$$

Normierung



$$\sqrt{\sum_{k=1}^t w_{ik}^2 \cdot \sum_{k=1}^t w_{jk}^2}$$



Dice-Koeffizient

$$sim_{D_i, D_j} = \frac{2 \cdot \sum_{k=1}^t (w_{ik} \cdot w_{jk})}{\sum_{k=1}^t w_{ik}^2 + \sum_{k=1}^t w_{jk}^2}$$



Jaccard-Koeffizient

$$sim_{D_i, D_j} = \frac{\sum_{k=1}^t (w_{ik} \cdot w_{jk})}{\sum_{k=1}^t w_{ik}^2 + \sum_{k=1}^t w_{jk}^2 - \sum_{k=1}^t (w_{ik} \cdot w_{jk})}$$

$$J(X, Y) = \frac{|X \cap Y|}{|X \cup Y|}$$



Ähnlichkeitsmatrix

- Ähnlichkeitsmaße erzeugen symmetrische Ähnlichkeitsmatrix
- Abspeichern als invertierte Liste

$$SIM = \begin{pmatrix} sim_{D_2,D_1} & & & & \\ sim_{D_3,D_1} & sim_{D_3,D_2} & & & \\ sim_{D_4,D_1} & sim_{D_4,D_2} & sim_{D_4,D_3} & & \\ \vdots & \vdots & \vdots & \ddots & \\ sim_{D_N,D_1} & sim_{D_N,D_2} & sim_{D_N,D_3} & \dots & sim_{D_N,D_{N-1}} \end{pmatrix}$$

Cluster-Verfahren

- Hierarchische Verfahren
- Nichthierarchische Verfahren




Nichthierarchische Ansätze zur Cluster-Bildung

Varianten

- Erzeugung von Clustern
- Aktualisierung von Clustern




Clique-Technik als erzeugendes nichthierarchisches Verfahren



- Jedes Element eines Clusters hat Ähnlichkeit über Schwellenwert zu jedem anderen Element des Clusters
- Maximale Cluster (Cliques) werden gesucht
- Probleme:
 - Ein Element kann mehreren Clustern angehören
 - Cluster kann nur ein Element enthalten
 - Aufwändige Berechnung

Star-Technik als erzeugendes nichthierarchisches Verfahren



- Unterscheidung Satellit- und Cluster-Knoten
- Cluster-Knoten bildet Cluster mit Satellitenknoten ähnlicher als Schwellenwert zu Cluster-Knoten
- Ein Element kann in mehreren Clustern vorkommen
- Quadratischer Aufwand

Reallokationstechnik als aktualisierendes, nichthier. Verf.

- Zuordnung neues Element zum besten Cluster
 - Zu jedem Cluster wird Zentroid (künstliches Durchschnittselement) verwaltet
 - Berechnung Ähnlichkeit zu jedem Zentroid
 - Zuordnung zum ähnlichsten Zentroid
 - Neuberechnung der Zentroiden
 - Neuuzuordnung aller Elemente bzgl. neuem Zentroid
 - Zentroide müssen dann wieder angepasst werden ...
- Wiederholung bis Stabilität erreicht
- Einsatz etwa nach Star-Technik



Festlegung des Schwellenwerts

- Zu hoch $\Rightarrow$ einelementige Cluster
- Zu niedrig $\Rightarrow$ sehr umfangreiche Cluster
- Diesbezüglich besser sind hierarchische Verfahren



Hierarchische Ansätze zur Cluster-Bildung

■ Varianten

- **Agglomerative** Verfahren: sukzessives Verschmelzen einelementiger Cluster
 - **Teilende** Verfahren: sukzessive Zerlegung N-elementiger Cluster in kleinere Cluster
-
- Vorteil: relativ geringer Berechnungsaufwand, da Cluster-Variantenanzahl schrittweise reduziert wird
 - Nachteil: einmal getroffene Entscheidungen können nicht mehr revidiert werden



Agglomerative Verfahren

Varianten, wie Cluster verschmolzen werden

- Single Link
- Complete Link
- Average Link
- Zentroid-Methode
- Ward's Methode



Single Link

- Cluster mit größter Ähnlichkeit werden zusammengefasst
- Ähnlichkeit zwischen Clustern als **maximale** Ähnlichkeit zwischen ihren Elementen

$$MAX_{x \in A; y \in B} sim(x, y)$$

- Nachteil: große Cluster tendieren zur Vergrößerung



Complete Link

- Cluster mit größter Ähnlichkeit werden zusammengefasst
- Ähnlichkeit zwischen Clustern als **minimale** Ähnlichkeit zwischen ihren Elementen

$$MIN_{x \in A; y \in B} sim(x, y)$$

- kleine Cluster werden bei Verschmelzung bevorzugt



Average Link

- Cluster mit größter Ähnlichkeit werden zusammengefasst
- Ähnlichkeit zwischen Clustern als durchschnittliche Ähnlichkeit zwischen ihren Elementen

$$\frac{1}{|A \times B|} \cdot \sum_{x \in A; y \in B} sim(x, y)$$

- Kompromiss zwischen Single und Complete Link



Zentroid Link

- Cluster mit größter Ähnlichkeit werden zusammengefasst
- Ähnlichkeit zwischen Clustern als Ähnlichkeit zwischen ihren Zentroiden




Ward's Methode

- Cluster mit kleinster **Fehlersumme** werden verschmolzen
- Fehlersumme ist Quadrate der einzelnen Euklidischen Distanzen der Cluster-Elemente
- Vorteil: homogene Cluster und symmetrische Cluster-Hierarchie
- Nachteil: hoher Berechnungsaufwand



Agglomerative hierarchische Cluster-Verfahren: Dendrogramm



Allgemeiner Algorithmus für agglomerative Verfahren

Grundlage: Ähnlichkeitsmatrix

1. Start mit N einelementigen Clustern (entspr. durchnummeriert)
2. Suche nach Paar (x,y) mit höchster Ähnlichkeit
3. Verschmelzen von x und y:
 1. Verschmelzen der Spalten und Zeilen von x und y
 2. Neuer Wert ist Maximum bei Single Link (analog für die anderen Verfahren)
 3. Neuer Cluster bekommt kleinere Nummer der Ursprungscluster
4. Schritte werden N-1 oft wiederholt



Beispiel Average Link

$$\frac{1}{|A \times B|} \cdot \sum_{x \in A; y \in B} \text{sim}(x, y)$$

Wie berechnen sich die neuen Ähnlichkeitswerte?

		Cluster 1	Cluster 2	Cluster 3	Cluster 4	Cluster 5	Cluster 6
		$\{D_1\}$	$\{D_2\}$	$\{D_3\}$	$\{D_4\}$	$\{D_5\}$	$\{D_6\}$
Cluster 1	$\{D_1\}$	∞	4	0	13	8	16
Cluster 2	$\{D_2\}$	4	∞	3	2	9	3
Cluster 3	$\{D_3\}$	0	3	∞	0	4	5
Cluster 4	$\{D_4\}$	13	2	0	∞	8	20
Cluster 5	$\{D_5\}$	8	9	4	8	∞	3
Cluster 6	$\{D_6\}$	16	3	5	20	3	∞



Verschmelzen von Cluster 4 und 6

		Cluster 1	Cluster 2	Cluster 3	Cluster 4	Cluster 5
		$\{D_1\}$	$\{D_2\}$	$\{D_3\}$	$\{D_4, D_6\}$	$\{D_5\}$
Cluster 1	$\{D_1\}$	∞	4	0	14,5	8
Cluster 2	$\{D_2\}$	4	∞	3	2,5	9
Cluster 3	$\{D_3\}$	0	3	∞	2,5	4
Cluster 4	$\{D_4, D_6\}$	14,5	2,5	2,5	∞	5,5
Cluster 5	$\{D_5\}$	8	9	4	5,5	∞



Verschmelzen von Cluster 1 und 4

$$\frac{1}{|A \times B|} \cdot \sum_{x \in A; y \in B} \tilde{sim}(x, y)$$

		Cluster 1	Cluster 2	Cluster 3	Cluster 5
		$\{D_1, D_4, D_6\}$	$\{D_2\}$	$\{D_3\}$	$\{D_5\}$
Cluster 1	$\{D_1, D_4, D_6\}$	∞	3	1,67	6,33
Cluster 2	$\{D_2\}$	3	∞	3	9
Cluster 3	$\{D_3\}$	1,67	3	∞	4
Cluster 5	$\{D_5\}$	6,33	9	4	∞



Verschmelzen von Cluster 2 und 5

		Cluster 1	Cluster 2	Cluster 3
		$\{D_1, D_4, D_6\}$	$\{D_2, D_5\}$	$\{D_3\}$
Cluster 1	$\{D_1, D_4, D_6\}$	∞	4,67	1,67
Cluster 2	$\{D_2, D_5\}$	4,67	∞	3,5
Cluster 3	$\{D_3\}$	1,67	3,5	∞



Verschmelzen von Cluster 1 und 2


		Cluster 1	Cluster 3
		$\{D_1, D_4, D_6, D_2, D_5\}$	$\{D_3\}$
Cluster 1	$\{D_1, D_4, D_6, D_2, D_5\}$	∞	2,4
Cluster 3	$\{D_3\}$	2,4	∞

Verschmelzen der restlichen Cluster

		Cluster 1
		$\{D_1, D_4, D_6, D_2, D_5, D_3\}$
Cluster 1	$\{D_1, D_4, D_6, D_2, D_5, D_3\}$	∞



Ablauf der Cluster-Bildung



Anwendungsgebiete für Cluster-Verfahren

- Automatische Thesaurus-Erzeugung
- Suche entlang einer Cluster-Hierarchie
- Aufbereitung des Ergebnisses einer Anfrage
- Wartung einer Klassifikation



Automatische Thesaurus-Erzeugung

- Thesaurus zur Erhöhung Recall-Wert
- Statt manuell erstelltem Thesaurus **Term-Clustering**
- Anwendung Star-Technik
- Ausgangspunkt: **Term× Dokument-Matrix**, Vorkommenshäufigkeiten in den Zellen



Beispiel: Term×Dokument-Matrix

	D_1	D_2	D_3	D_4	D_5	D_6	D_7
t_1	0	4	0	3	0	1	0
t_2	3	0	4	0	0	0	0
t_3	0	2	0	2	0	0	0
t_4	1	0	0	4	0	0	0
t_5	2	0	2	0	3	0	0
t_6	0	3	0	0	3	0	2
t_7	2	0	7	0	0	0	0
t_8	0	4	0	4	0	0	0
t_9	0	0	0	0	3	0	6
t_{10}	0	1	0	0	2	0	4

Beispiel: Term×Term-Ähnlichkeit

Hier Zähler des Dice-Koeffizienten und Schwellenwert 40

	t_1	t_2	t_3	t_4	t_5	t_6	t_7	t_8	t_9	t_{10}
t_1	52	0	28	24	0	24	0	56	0	8
t_2	0	50	0	6	28	0	68			0
t_3	28	0	16	16	0	12	0	32	0	4
t_4	24	6	16	34	4	0	4	32	0	0
t_5	0	28	0	4	34	18	36	0	18	12
t_6	24	0	12	0	18	44	0	24	42	34
t_7	0	68	0	4	36	0	106	0	0	0
t_8	56		32	32	0	24	0	64	0	8
t_9	0		0	0	18	42	0	0	90	60
t_{10}	8		4	0	12	34	0	8	60	42

Beispiel: Term×Dokument-Matrix

	D_1	D_2	D_3	D_4	D_5	D_6	D_7
t_1	0	4	0	3	0	1	0
t_2	3	0	4	0	0	0	0
t_3	0	2	0	2	0	0	0
t_4	1	0	0	4	0	0	0
t_5	2	0	2	0	3	0	0
t_6	0	3	0	0	3	0	2
t_7	2	0	7	0	0	0	0
t_8	0	4	0	4	0	0	0
t_9	0	0	0	0	3	0	6
t_{10}	0	1	0	0	2	0	4



Suche entlang einer Cluster-Hierarchie

- Navigation von Wurzel zu Blättern entlang eines Dendogramms
- Jeder Cluster wird durch typisches Dokument (am ähnlichsten zum Zentroid) repräsentiert
- Vorteil: Anfrage muss nicht formuliert werden (gehört zum **Browsing**)



Aufbereitung des Ergebnisses einer Anfrage

- Strukturierung Anfrageergebnis ohne Sortierung (Boolesches Retrieval) durch Bildung thematischer Cluster
- Sinnvoll auf Ergebnis mit Rangordnung zum Trennen inhaltlicher Ausrichtungen
- Problem: keine explizite Beschreibung der Cluster
- Besser: Klassifikation, dafür aber hoher manueller Aufwand



Wartung einer Klassifikation

- Zuordnung neues Dokument zur Klassifikation mittels Cluster-Verfahren, etwa Single-Link
- Zweiter Schritt: Reallocation-Technik zur Überprüfung der aktuellen Zuordnung
- Test, ob Klassifikation schlüssig ist (mittels Ähnlichkeitsmatrix)



6.3 Browsing

- **Browsing:** Navigierender Zugriff auf Informationen
 - Weitere Aspekte: Durchstöbern, Überfliegen
- Setzt entsprechende Aufbereitung der Dokumentkollektion voraus
 - Literaturverzeichnisse und Referenzen
 - Klassifikationen
 - Hypertext-Dokumente
 - Cluster und Cluster-Hierarchien
 - Visuelle Darstellung von Dokumentkollektionen



Literaturverzeichnisse und Referenzen

- Wissenschaftliche Arbeiten enthalten Literaturverzeichnisse und Referenzen
- Aufwand zum Verfolgen einer Referenz sehr hoch



Klassifikationen

- Betrachten der Dokumente in der selben Klasse
- Klassenhierarchie: speziellere oder allgemeinere Dokumente betrachten
- Browsen von Wurzel bis zu den Blättern



Hypertext-Dokumente

- Hypertext-Formate wie HTML enthalten Verweise auf andere Stellen im Dokument oder andere Dokumente
- Keine klar vorgegebene Struktur, sondern Netz von Verweisen
- Hohe Gefahr des Verlaufs, daher meist in Kombination mit Suchmaschinensuche und Katalogen



Cluster und Cluster-Hierarchien

- Betrachten von Dokumenten im gleichen Cluster
- Suche entlang Cluster-Hierarchie



Visuelle Darstellung von Dokumentkollektionen

- Idee: komplexe Zusammenhänge leichter graphisch als textuell erfassbar
- Einsatz von Navigationshilfen im Dokumentraum
- Problem der Informationsvisualisierung




1-dimensionale lineare Darstellung

- Sortierte Liste von Dokumenten
- Sortierung etwa durch Klassifikation oder Veröffentlichungsdatum




Beispiel: Dokumentation der Java-API



2-dimensionale Darstellung

- Anordnung in der Ebene
- Varianten der Anordnung
 - Dimensionsreduzierung auf 2 Dimensionen
 - Darstellung von Cluster-Hierarchien (in Kombination mit Dimensionsreduzierung)
 - Anordnung anhand Kräften der Anziehung und Abstoßung

Beispiel: ET-Map



3-dimensionale Darstellung


- Weitere Dimension, etwa Höhenlinien
- Höhe kann etwa Anzahl Dokumente zum Thema bedeuten (NewsMap)
- Zeitdimension (perspective wall)
- Darstellung zusätzlicher Dimensionen kodiert mittels Icons, Größe und Form von Gegenständen



NewsMap



Perspective Wall




Mehrdimensionale Darstellung


- Zusätzliche Dimensionen darstellbar mittels Icons, Farben, Größe von Symbolen
- Ab ca. 7 Dimensionen nicht mehr sinnvoll
- Ansatz von Matt Ward (Kriterien von Kraftfahrzeugen)




Kriterien von Kraftfahrzeugen




Baumartige Darstellung



Darstellung als Netzwerk



Scatter Plot



Grundlagen der Visualisierung von Dokumentkollektionen

- „**visual-information-seeking-mantra**“ von Ben Shneiderman: „Overview first, zoom and filter, then detail on demand“
- Möglichst ähnlichkeits- bzw. distanzbasiertes Einbetten von Dokumenten oder Gruppen in 1-, 2-, oder mehrdimensionalen Vektorraum



Aufgaben der Informationsvisualisierung

Aufgabe	Beschreibung
Overview	Gib einen Überblick über die gesamte Kollektion.
Zoom	Stelle die aktuell interessierenden Elemente vergrößert (detaillierter) dar.
Filter	Verberge Elemente, die aktuell nicht von Interesse sind.
Details-on-Demand	Erlaube die Selektion eines Elements oder einer Gruppe und zeige die zugehörigen Detailinformationen an.
Relate	Zeige die Zusammenhänge und Verbindungen zwischen den Elementen auf (z.B. inhaltliche Bezüge oder Zitationen).
History	Die vorangegangenen Aktionen sollten gespeichert werden, um Operationen wie <i>Undo</i> , <i>Replay</i> oder eine <i>proaktive Verfeinerung</i> durchführen zu können.
Extract	Erlaube die Extraktion von Teilkollektionen oder Anfrageparametern.

