

Information Retrieval: Probabilistisches Retrieval



Ingo Schmitt

Brandenburgische Universität Cottbus

Institut für Informatik

Lehrstuhl für Datenbank- und Informationssysteme



Überblick

- Bisher: keine theoretisch fundierten Modelle, aber trotzdem gute Ergebnisse
- Ziel: Theoretisches Fundament für das Retrieval
- Binary Independence Retrieval-Modell (BIR)
- Der aktuelle Standard: Okapi BM 25



Was soll berechnet werden?

- Wahrscheinlichkeit, dass ein Dokument D relevant bezüglich einer Anfrage Q ist
- Chance:
 - Wahrscheinlichkeit für Relevanz/Wahrscheinlichkeit für Irrelevanz



Binary Independence Retrieval

- Robertson/Sparck Jones [1976]
- Grundannahmen:
 - Binäre Termgewichte, d.h. $w_{dk} \in \{0,1\}$
 - vgl. $[0,1]$ beim Vektorraummodell
 - Unabhängigkeitsannahme der einzelnen Dimensionen des Repräsentationsvektors
 - wie beim Vektorraummodell



Definitionen

- Dokument: D
- Anfrage: Q
- Menge der relevanten Dokumente: $R^+(Q)$
- Wahrscheinlichkeit, dass D zu Q relevant ist

$$P(D \in R^+(Q))$$

- Repräsentation eines Dokument: $\beta(D)$
- Dimensionalität (#Terme): t



Kernidee

- Bedingte Wahrscheinlichkeit, dass Dokument D' , welches die gleiche Repräsentation wie D hat relevant für die Anfrage Q ist

$$P(D' \in R^+(Q) | \beta(D') = \beta(D))$$

- eigentlich: Wahrscheinlichkeit der Relevanz für *alle* Dokumente gleicher Repräsentation



Beispiel

	D1	D2	D3	D4	D5	D6	D7	D8	D9
w_{d1}	1	1	1	0	0	0	1	1	0
w_{d2}	1	0	1	0	1	0	1	0	0
Relevanz	✓	✓	✓	✗	✗	✗	✗	✗	✗

$$P(D' \in R^+(Q) | \beta(D') = x)$$

x	P(...)
(1,1)	2/3, da (1,1) 3x vorkommt und 2x relevant ist
(1,0)	1/2
...	...

Beispiel – Ein neues Dokument


	D1	D2	D3	D4	D5	D6	D7	D8	D9	D10
w_{d1}	1	1	1	0	0	0	1	1	0	1
w_{d2}	1	0	1	0	1	0	1	0	0	0
Relevanz	✓	✓	✓	✗	✗	✗	✗	✗	✗	?

$$P(D' \in R^+(Q) | \beta(D') = x)$$

Relevanzwahrscheinlichkeit für D10 ist $\frac{1}{2}$, da in Klasse (1,0)

Offenes Problem

- Wie ermittelt man die Relevanzwahrscheinlichkeiten empirisch?
- 2^t mögliche Repräsentationen
- Zur Bewertung benötigt man weit mehr als 2^t Dokumente!




Die ideale Antwort

- Annahme, dass es eine *ideale Antwort* gibt, die sämtliche relevante Dokumente bzgl. Q enthält
- Gesucht: Repräsentation dieser Antwort
- Problem: Wir kennen sie nicht!
- Annäherung per Relevance Feedback an die Repräsentation der idealen Antwort
 - Repräsentation der idealen Antwort enthält pro Dimension entweder 1 oder 0



Eigenschaften der idealen Antwort



Weitere Annahmen

- Wahrscheinlichkeit, dass D für Q relevant ist hängt nur von Anfragerepräsentation und Dokumentenrepräsentation ab
- Es existiert eine ideale Antwort $R^+(Q)$
- **Chance**, dass D relevant bzgl. Q ist:

$$\frac{P(D \in R^+(Q))}{P(D \notin R^+(Q))}$$



Chance

- Wenn Wahrscheinlichkeit für Relevanz 0 wird, dann ist Chance auch 0
- Für Relevanzwahrscheinlichkeit von 1 strebt Chance gegen unendlich
- Chance wächst monoton

■ d.h. es ist egal ob nach Chance oder Wahrscheinlichkeit sortiert wird

$$\frac{P(D \in R^+(Q))}{P(D \notin R^+(Q))}$$



Weitere Definitionen

- Komplement zu $R^+(Q)$ ist $R^-(Q)$: binäres Relevanzurteil
 - d.h. Vereinigung sind alle Dokumente
- Gewichte der Repräsentationssvektoren sind binär, d.h. $w_{dk} \in \{0, 1\}$
 - gilt für Dokumente und Anfrage



Rankingkriterium

- Ähnlichkeit zwischen D und Q

$$\text{sim}(D, Q) = \frac{P(D' \in R^+(Q) | \beta(D') = \beta(D))}{P(D' \in R^-(Q) | \beta(D') = \beta(D))}$$

- Chance, dass D' relevant ist, wenn es die gleiche Repräsentation wie D hat



Exkurs: Bayes' Theorem

- Beschäftigt sich mit bedingten Wahrscheinlichkeiten, z.B. a unter Bedingung b

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$
$$P(b|a) = \frac{P(a \wedge b)}{P(a)}$$



Beispiel zu Bayes' Theorem

- $P(b) = 10\%$
- $P(a \wedge b) = 5\%$
- $P(a|b) = 0,05/0,1 = 0,5 \Rightarrow 50\%$



Umformungen bei Bayes

- Manchmal kann es günstiger sein, über leicht zu bestimmende Wahrscheinlichkeiten auf andere zu schließen

$$P(b|a) = \frac{P(a \wedge b)}{P(a)} \quad | \cdot P(a)$$
$$P(a) * P(b|a) = P(a \wedge b)$$



Umformungen bei Bayes

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$
$$P(a|b) = \frac{P(a) * P(b|a)}{P(b)}$$



Einsetzen in Chance

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$

$$P(a|b) = \frac{P(a) * P(b|a)}{P(b)}$$

a

b

$$sim(D, Q) = \frac{P(D' \in R^+(Q) | \beta(D') = \beta(D))}{P(D' \in R^-(Q) | \beta(D') = \beta(D))}$$

$$sim(D, Q) = \frac{P(D' \in R^+(Q)) \cdot P(\beta(D') = \beta(D) | D' \in R^+(Q))}{P(\beta(D') = \beta(D))}$$

$$\cdot \frac{P(\beta(D') = \beta(D))}{P(D' \in R^-(Q)) \cdot P(\beta(D') = \beta(D) | D' \in R^-(Q))}$$

$$= \frac{P(D' \in R^+(Q)) \cdot P(\beta(D') = \beta(D) | D' \in R^+(Q))}{P(D' \in R^-(Q)) \cdot P(\beta(D') = \beta(D) | D' \in R^-(Q))}$$



Weitere Vereinfachung

- Wahrscheinlichkeit, dass beliebiges Dokument (ir)relevant ist, bleibt pro Anfrage konstant

$$\begin{aligned}
 \text{sim}(D, Q) &= \frac{P(D' \in R^+(Q)) \cdot P(\beta(D') = \beta(D) \mid D' \in R^+(Q))}{P(\beta(D') = \beta(D))} \\
 &\quad \cdot \frac{P(\beta(D') = \beta(D))}{P(D' \in R^-(Q)) \cdot P(\beta(D') = \beta(D) \mid D' \in R^-(Q))} \\
 &= \boxed{\frac{P(D' \in R^+(Q))}{P(D' \in R^-(Q))}} \cdot \frac{P(\beta(D') = \beta(D) \mid D' \in R^+(Q))}{P(\beta(D') = \beta(D) \mid D' \in R^-(Q))}
 \end{aligned}$$

Vorläufiges Endergebnis

$$\text{sim}(D, Q) \approx \frac{P(\beta(D') = \beta(D) | D' \in R^+(Q))}{P(\beta(D') = \beta(D) | D' \in R^-(Q))}$$

■ Zähler:

- Wahrscheinlichkeit, dass Repräsentation gegeben, wenn das Dokument relevant ist

■ Nenner:

- Wahrscheinlichkeit, dass Repräsentation gegeben, wenn es irrelevant ist

Beispiel

	D1	D2	D3	D4	D5	D6	D7	D8	D9
w_{d1}	1	1	1	0	0	0	1	1	0
w_{d2}	1	0	1	0	1	0	1	0	0
Relevanz	✓	✓	✓	✗	✗	✗	✗	✗	✗

Neues Dokument $D11=(1,1)$, $\text{sim}(D11, Q)=4$

$$\text{sim}(D, Q) \approx \frac{P(\beta(D') = \beta(D) | D' \in R^+(Q))}{P(\beta(D') = \beta(D) | D' \in R^-(Q))}$$

2/3
1/6



Beispiel

	D1	D2	D3	D4	D5	D6	D7	D8	D9
w_{d1}	1	1	1	0	0	0			
w_{d2}	1	0	1	0					
Relevanz	✓	✓							

**Immer noch das offene Problem:
Wie bestimmt man bei 2^t Möglichkeiten
genügend Stichproben?**

$$\frac{\beta(D) | D' \in R^+(Q)}{\beta(D) | D' \in R^-(Q)}$$

2/3
1/6



Komponentenweise Bewertung

- Man bestimmt Wahrscheinlichkeiten nicht mehr pro Beschreibungsvektor, sondern je Vektorkomponente
- Wir ersetzen $\beta(D')=\beta(D)$ durch komponentenweise Gleichheit

$$sim(D, Q) \approx \frac{P(\forall_{\{i|w_{di}=1\}}(w_{d'i}=1) \wedge \forall_{\{i|w_{di}=0\}}(w_{d'i}=0) | D' \in R^+(Q))}{P(\forall_{\{i|w_{di}=1\}}(w_{d'i}=1) \wedge \forall_{\{i|w_{di}=0\}}(w_{d'i}=0) | D' \in R^-(Q))}$$



Die „Independence“ im BIR-Modell

$$\text{sim}(D, Q) \approx \frac{P(\forall_{\{i|w_{di}=1\}}(w_{d'i}=1) \wedge \forall_{\{i|w_{di}=0\}}(w_{d'i}=0) | D' \in R^+(Q))}{P(\forall_{\{i|w_{di}=1\}}(w_{d'i}=1) \wedge \forall_{\{i|w_{di}=0\}}(w_{d'i}=0) | D' \in R^-(Q))}$$

- Annahme, dass alle Komponenten voneinander unabhängig sind, dann gilt: $P(a \wedge b) = P(a) * P(b)$

$$\text{sim}(D, Q) \approx \frac{\left(\prod_{\{i|w_{di}=1\}} P(w_{d'i}=1 \mid D' \in R^+(Q)) \right)}{\left(\prod_{\{i|w_{di}=1\}} P(w_{d'i}=1 \mid D' \in R^-(Q)) \right)} \cdot \frac{\left(\prod_{\{i|w_{di}=0\}} P(w_{d'i}=0 \mid D' \in R^+(Q)) \right)}{\left(\prod_{\{i|w_{di}=0\}} P(w_{d'i}=0 \mid D' \in R^-(Q)) \right)}$$



Weitere Umformungen

- Ziel: Vermeidung der Produktbildung über alle Terme
- Wir wissen:
 - $\log(a_1 * a_2 * a_3) = \log(a_1) + \log(a_2) + \log(a_3)$
 - wenn $a_1 > a_2 > a_3$, dann gilt das auch für deren Logarithmen



Endgültige Formel

- Unter folgenden Annahmen gilt dann:
 - Binäres Relevanzurteil ($P(R^+) + P(R^-) = 1$)
 - Wir betrachten nur Anfrageterme = 1
 - Wir können alle Faktoren weglassen, die für alle Dokumente bzgl. der Anfrage gleich sind oder so angenommen werden

$$sim(D, Q) \approx \sum_{\{i | w_{qi} = w_{di} = 1\}} \left(\log \frac{P(w_{d'i} = 1 \mid D' \in R^+(Q))}{1 - P(w_{d'i} = 1 \mid D' \in R^+(Q))} + \log \frac{1 - P(w_{d'i} = 1 \mid D' \in R^-(Q))}{P(w_{d'i} = 1 \mid D' \in R^-(Q))} \right)$$



Bestimmung des initialen Ergebnisses

- Gesucht: Schätzung, dass $P(w_{d'i} = 1 | D' \in R^+(Q))$
bzw. $P(w_{d'i} = 1 | D' \in R^-(Q))$

- Annahme: gleich häufig, d.h.:

$$P(w_{d'i} = 1 | D' \in R^+(Q)) = 0,5$$

- $P(w_{d'i} = 1 | D' \in R^-(Q)) = n_i / N$



Bestimmung des initialen Ergebnisses

$$\begin{aligned} \text{sim}(D, Q) &\approx \sum_{\{i | w_{qi} = w_{di} = 1\}} \left(\log \frac{0,5}{0,5} + \log \frac{1 - \frac{n_i}{N}}{\frac{n_i}{N}} \right) \\ &= \sum_{\{i | w_{qi} = w_{di} = 1\}} \log \frac{N - n_i}{n_i} \end{aligned}$$

- Starke Ähnlichkeit zur $\text{tf} \cdot \text{idf}$ -Formel
 - *Idf*: $N - n_i \approx N$ für großes N
 - *Tf*: wegen *Summenindex* und *binären Werten*



Beispiel

- Indexvokabular $t=8$
- Anfragevektor $Q=(1,0,0,1,1,0,0,0)$
- Anzahl der Dokumente $N=500$
- $n_1=87; n_4=23; n_5=100$
- Dokument $D=(1,0,0,0,1,1,0,0)$

$$\text{sim}(D, Q) = \log\left(\frac{500 - 87}{87}\right) + \log\left(\frac{500 - 100}{100}\right) \approx 1,28$$



Anpassung des initialen Ergebnisses

■ Idee des Relevance Feedbacks

■ Pseudo-Relevance

- Feedback benötigt keine Nutzerinteraktion
- V sei die Menge der r höchsten gerankten Dokumente

■ Echtes Relevanz Feedback

- V^* sei die Menge der positiv bewerteten Dokumente



Anpassung nach Relevanz Feedback

$$P(w_{d'i} = 1 \mid D' \in R^+(Q)) = \frac{|\{D' \in V \mid w_{d'i} = 1\}|}{|V|}$$

$$P(w_{d'i} = 1 \mid D' \in R^-(Q)) = \frac{n_i - |\{D' \in V \mid w_{d'i} = 1\}|}{N - |V|}$$



Varianten bei sehr kleinen Mengen V

$$P(w_{d'i} = 1 \mid D' \in R^+(Q)) = \frac{|\{D' \in V \mid w_{d'i} = 1\}| + 0,5}{|V| + 1}$$

$$P(w_{d'i} = 1 \mid D' \in R^-(Q)) = \frac{n_i - |\{D' \in V \mid w_{d'i} = 1\}| + 0,5}{N - |V| + 1}$$

■ oder

$$P(w_{d'i} = 1 \mid D' \in R^+(Q)) = \frac{|\{D' \in V \mid w_{d'i} = 1\}| + \frac{n_i}{N}}{|V| + 1}$$

$$P(w_{d'i} = 1 \mid D' \in R^-(Q)) = \frac{n_i - |\{D' \in V \mid w_{d'i} = 1\}| + \frac{n_i}{N}}{N - |V| + 1}$$



Kritik am BIR-Modell

- Unabhängigkeitsannahme der einzelnen Komponenten (wie beim Vektorraummodell)
- Initiales Ergebnis wird sehr grob geschätzt, Relevance Feedback wird notwendig
 - Verbesserung nur für eine Anfrage gültig, kein Lernen
- Binäre Gewichtung löst gröber auf als das Vektorraummodell

Experimente

eingesetzte Methode		CACM 1033 Dok. 30 Anfr.	CISI 12684 Dok. 84 Anfr.	CRAN 1397 Dok. 225 Anfr.	INSPEC 1460 Dok. 112 Anfr.	MED 3204 Dok. 64 Anfr.	Durchschnitt
initiale Anfrage							
	Precision	0,1459	0,1184	0,1156	0,1368	0,3346	
IDE (dec hi)							
mit allen Termen	Precision	0,2704	0,1742	0,3011	0,2140	0,6305	
	Verbesserung	+86%	+47%	+160%	+56%	+88%	+87%
ausgewählte Terme	Precision	0,2479	0,1924	0,2498	0,1976	0,6218	
	Verbesserung	+70%	+63%	+116%	+44%	+86%	+76%
BIR-Modell							
mit allen Termen	Precision	0,2289	0,1436	0,3108	0,1621	0,5972	
	Verbesserung	+57%	+21%	+169%	+19%	+78%	+69%
ausgewählte Terme	Precision	0,2224	0,1634	0,2120	0,1876	0,5643	
	Verbesserung	+52%	+38%	+83%	+37%	+69%	+56%

Okapi BM25

- von Robertson/Sparck Jones entwickelt
- erstmals im Okapi-System der City University (London) eingesetzt
- erfolgreich bei TREC eingesetzt
- basiert auf probabilistischem Retrieval
- Kombiniert TF-IDF-Variante mit probabilistischem Retrieval



BM25

$$sim(D, Q) = \sum_{i=1}^t IDF(n_i) * \frac{(k_1+1)tf_{di}}{k_1((1-b)+b\frac{dl}{avdl})+tf_{di}} * \frac{(k_3+1)tf_{qi}}{k_3+tf_{qi}}$$

$$IDF(n_i) = \log \frac{N-n_i+0,5}{n_i+0,5}$$

- k_1 (zwischen 1, 0 und 2, 0), b (normalerweise 0, 75) und k_3 (zwischen 0 und 1000) sind Konstanten
- dl : Länge des Dokuments in Worten
- $avdl$: Durchschnittliche Länge der Dokumente



BM25 vs. Vektorraummodell

$$sim(D, Q) = \sum_{i=1}^t IDF(n_i) * \frac{(k_1+1)tf_{di}}{k_1((1-b)+b\frac{dl}{avdl})+tf_{di}} * \frac{(k_3+1)tf_{qi}}{k_3+tf_{qi}}$$

$$IDF(n_i) = \log \frac{N-n_i+0,5}{n_i+0,5}$$


Achtung! Bei $n_i > N/2$ kann IDF negativ werden:

- z.B. Null setzen



$$w_{dk} = \frac{tf_{dk} \log \frac{N}{n_k}}{\sqrt{\sum_{i=1}^t \left(tf_{di} \log \frac{N}{n_i} \right)^2}}$$

Exkurs: Slope

- Beim Vektorraummodell sollte durch Normierung die Benachteiligung kurzer Dokumente behoben werden
- Problem: kurze Dokumente enthalten wenig Terme, d.h. deren Beschreibungsvektoren haben wenige Komponenten mit $w_{dk} > 0$



Exkurs: Slope

■ Ergebnis:

- kurze Dokumente haben nach Normierung große Komponentenwerte, da normierte Länge 1 auf wenig Komponenten „aufgeteilt“ wird
 - lange Dokumente haben kleine Komponentenwerte
- ➔ bei wenigen Anfragetermen werden Dokumente mit hohen w_{dk} -Werten bevorteilt (kurze Dokumente)

Exkurs: Slope

- Alte Normierung wird ersetzt durch:

$$\sqrt{\sum_{i=1}^t \left(tf_{di} \cdot \log \frac{N}{n_i} \right)^2} = \sqrt{\sum_{i=1}^t w_{di}^2}$$

$$kf_d = (1 - slope) + slope \cdot \frac{old_normalization}{average_old_normalization}$$

- Slope meist im Bereich 0,65-0,75 (empirisch bestimmen)
- Neuer $w_{dk} = kf_d * w_{dk}$



Slope bei BM25

$$sim(D, Q) = \sum_{i=1}^t IDF(n_i) * \frac{(k_1+1)tf_{di}}{k_1((1-b)+b\frac{dl}{avdl})+tf_{di}} * \frac{(k_3+1)tf_{qi}}{k_3+tf_{qi}}$$

$$IDF(n_i) = \log \frac{N-n_i+0,5}{n_i+0,5}$$

- b und k_1 steuern die Slope vgl.
Vektorraummodell

$$kf_d = (1 - slope) + slope \cdot \frac{old_normalization}{average_old_normalization}$$

